

**T.C.
SAKARYA ÜNİVERSİTESİ
BİLGİSAYAR VE BİLİŞİM BİLİMLERİ FAKÜLTESİ**

ISE 402 - Bitirme Projesi

**DERİN ÖĞRENME VE BÜYÜK DİL
MODELİ ENTEGRASYONU İLE
AÇIKLANABİLİR BEYAZ KAN
HÜCRESİ SINIFLANDIRMASI**

B211200004 Emirhan YILDIRIM

**Bölüm: Bilişim Sistemleri Mühendisliği
Danışman: Dr.Öğr.Üyesi Fatma AKALIN**

2025-2026 Bahar Dönemi

İçindekiler

1	Giriş	8
1.1	Problem Tanımı ve Mevcut Durum	8
1.1.1	Zaman ve iş gücü maliyeti	8
1.1.2	İnsan faktörüne bağlı hata riski	9
1.1.3	Standardizasyon eksikliği	9
1.2	Motivasyon	9
1.2.1	Derin öğrenme ve transfer learning stratejisi	9
1.2.2	Görüntü standardizasyonu (preprocessing)	10
1.2.3	Sistem entegrasyonu ve servis mimarisi	10
1.3	Projenin Özgün Değeri ve Beklenen Katkıları	10
1.3.1	Literatüre Özgün Algoritmik Katkıları	10
1.3.2	Endüstriyel Standartlarda Sistem Mimarisi	11
1.3.3	Veri İşleme ve Genelleme Yeteneği	11
1.3.4	Sosyal Etki ve Klinik Kullanılabilirlik	12
2	Literatür Taraması	13
2.1	Geleneksel Görüntü İşleme Yöntemleri	13
2.2	Derin Öğrenme Tabanlı Yöntemler	13
2.3	Referans Çalışma ve Projenin Konumu	13
2.4	Sağlıkta Yapay Zeka Modellerinin Dağıtımı ve Karşılaşılan Zorluklar	14
2.5	Tıbbi Modellerde Güvenilirlik ve Belirsizlik Yönetimi	14
2.6	Tıbbi Görüntüleme ve Sağlık Verilerinde Web Servis Yaklaşımları	15
2.7	Nesne Tespiti Mimarilerinin Evrimi ve Tıbbi Görüntülemede YOLO Modelleri	15
3	Materyal ve Metot	16
3.1	Materyal ve Geliştirme Ortamı	16
3.2	Veri Kümesi	16
3.2.1	Veri yapısı	17
3.2.2	Sınıf dağılımı	17
3.2.3	Veri ayrımı	17
3.3	Yöntem	19
3.3.1	Geliştirilen Özgün Ön İşleme: Medical Enhanced Filter	19
3.3.2	Transfer Learning Omurga Seçimi: Karşılaştırmalı Analiz	22
3.3.3	Model Mimarisi: DenseNet121 + Attention + MedSwish	23
3.3.4	Eğitim stratejisi ve kayıp fonksiyonu	25
3.4	Sistem Tasarımı ve API Mimarisi	26
3.5	Alan Kayması (Domain Shift) Yönetimi ve Çıkarım Zamanı (Inference) İyileştirmeleri	29
3.6	Kısayol Öğrenmeye (Shortcut Learning) Karşı Dirençli Eğitim Mimarisi	29

4	Araştırma Bulguları	30
4.1	Transfer Learning Omurga Karşılaştırması	30
4.2	Özgün Mimari (MedSwish & Attention) ve Eğitim Süreci	30
4.2.1	Karmaşıklık matrisi (confusion matrix) analizi	31
4.2.2	Deneyler Arası Karşılaştırmalı Analiz ve Kısayol Öğrenme Bulgusu	32
4.2.3	Inference-Time Domain Adaptasyonu ve Ablasyon Analizi	34
4.3	Omurga Modellerin Test Seti Performans Karşılaştırması	34
4.4	Ön İşleme Pipeline'ı Ablasyon Analizi	35
4.5	Web Servis ve Arayüz Performans Testleri	36
4.5.1	Doğruluk ve Güven Skoru Testleri	36
4.5.2	Hata Yönetimi ve Yük Testleri	36
4.5.3	Arayüz Çıktıları	36
5	Tartışma	39
5.1	Literatür Karşılaştırması	39
5.2	Ön İşleme Pipeline'ının Etkinliği	40
5.3	Sınıf Dengesizliği (Class Imbalance) ve Morfolojik Analiz	40
5.4	Kısayol Öğrenme (Shortcut Learning) ve Otonom Açıklanabilirlik (Agentic XAI)	41
5.5	Alan Kayması (Domain Shift) ve Çıkarım Zamanı Adaptasyonu (Test-Time Adaptation)	42
5.6	Klinik MLOps ve Web Servis Mimarisi	42
5.7	Önerilen Çözümün Özgün Katkıları	43
5.8	Kısıtlamalar	43
6	Sonuç	45
6.1	Sonuçlar	45
6.1.1	Transfer Learning Omurga Analizi ve Model Seçimi	45
6.1.2	Sınıflandırma Başarısı ve Parametre Verimliliği	45
6.1.3	Otonom Açıklanabilirlik (Agentic XAI)	45
6.1.4	Donanım Bağımsızlığı ve Çıkarım Zamanı Adaptasyonu	46
6.1.5	Klinik Entegrasyon ve Web Servis Mimarisi	46
6.2	Projenin Genel Değerlendirmesi	46
6.3	Gelecek Çalışmalar İçin Öneriler	47
6.3.1	Bütüncül Görüntü Analizi (Whole Slide Image)	47
6.3.2	Bayes Derin Öğrenme ile Belirsizlik Kalibrasyonu	47
6.3.3	Ölçeklenebilirlik ve Bulut Bilişim	47
6.3.4	Gizlilik Koruyucu Yapay Zeka	47
6.3.5	Farklı Boyama Protokolleri için Genişletilmiş Adaptasyon	47
6.3.6	Prospektif Klinik Validasyon	48

Şekil Listesi

1	Raabin-WBC veri setinden örnek görüntüler	17
2	Veri Seti Sınıf Dağılım-1	18
3	Veri Seti Sınıf Dağılımı-2	18
4	Preprocess Akış Diyagramı	20
5	Preprocess Karşılaştırma Görseli	22
6	Filtre Karşılaştırması	22
7	DenseNet Eğitim Grafiği	26
8	Sistem Akış Şeması	28
9	Karmaşıklık Matrisleri	32
10	Modelin tahmin yaparken odaklandığı pikselleri gösteren Grad-CAM Isı Haritası.	33
11	Web arayüzü üzerinden gerçekleştirilen örnek bir analiz ve LLM ajanı tarafından otonom olarak üretilen "AI Değerlendirme Raporu" ekranı . .	38

Tablo Listesi

1	Teknik Envanter	16
2	Önerilen Model Mimarisi ve Parametre Özeti	25
3	Transfer learning omurga mimarilerinin karşılaştırmalı analizi. Tüm modeller MEF ön işleme ve iki aşamalı eğitim protokolüyle eğitilmiştir. En iyi değerler kalın ile gösterilmiştir.	30
4	Sınıflandırma Raporu Tablosu	31
5	Farklı yöntemlerin TestA, TestB ve birleşik performans karşılaştırması. .	34
6	Tüm backbone modellerinin TestA (dağılım içi), TestB (domain shift) ve birleşik test seti performansları. final_model_results satırı inference-time adaptasyon pipeline'ı uygulanmış önerilen mimariye aittir. En iyi değerler kalın ile gösterilmiştir.	35
7	Aynı model üzerinde dört farklı ön işleme varyantının TestA, TestB ve birleşik performans karşılaştırması. En iyi değerler kalın ile gösterilmiştir.	35

Kod Bloęu Listesi

1	Özgün Medical Enhanced Filter (MEF)	21
2	WBC Attention Block Mimarisi	24
3	MedSwish Fonksiyonu	24

Algoritma Listesi

1	WBC Sınıflandırma Servisi Arka Plan İşleyişi	27
2	Otonom Kısayol Öğrenme (Shortcut Learning) Denetim Algoritması . . .	29

Özet

Tıbbi görüntüleme teknolojilerindeki gelişmeler ve yapay zeka tabanlı analiz yöntemleri, modern sağlık hizmetlerinde teşhis süreçlerinin hızını ve güvenilirliğini artırmada kritik bir rol oynamaktadır. Özellikle hematoloji laboratuvarlarında rutin olarak uygulanan periferik kan yayma testleri; enfeksiyonlar, alerjik reaksiyonlar, anemi ve lösemi gibi hayati hastalıkların teşhisinde "altın standart" olarak kabul edilmektedir. Ancak, lökosit sayımı ve sınıflandırmasının halen büyük ölçüde uzman hematologlar tarafından manuel yapılması; uzun inceleme süreleri, gözlemciler arası öznellik ve yorgunluğa bağlı hata risklerini beraberinde getirmektedir. Ayrıca klinik verilerdeki sınıf dengesizlikleri, farklı laboratuvarlardan kaynaklanan alan kayması ve derin öğrenme modellerinin arka plana odaklanarak "kısayol öğrenme" eğilimi göstermesi, otomasyon sistemlerinin klinik kullanıma geçişinin önündeki en büyük engellerdir.

Bu projede, manuel süreçlerin operasyonel zorluklarını ve söz konusu teknik engelleri aşmak amacıyla uçtan uca, klinik kullanıma hazır bir "Dijital Patoloji Asistanı" geliştirilmiştir. Tahran Üniversitesi tarafından sağlanan 12.000 görüntü Raabin-WBC veri setiyle eğitilen model, standart transfer öğrenme yaklaşımlarının ötesine geçmiştir. Sistem; DenseNet121 omurgasına entegre edilen, hücreyi arka plandaki gürültüden ayırt eden özgün "WBC Attention Block" ve negatif değerlerdeki bilgi kaybını önleyen "MedSwish" aktivasyon fonksiyonu ile güçlendirilmiştir. Yalnızca 7.83 milyon parametre kullanan bu hafif ve yüksek performanslı mimaride, nadir hücre sınıflarındaki dengesizlik problemi "WBC Focal Loss" ile çözülürken; farklı cihazlardan gelen görüntülerin kalite varyasyonları, hibrit bir "Medical Enhanced Filter" algoritması ile standartlaştırılmıştır.

Projenin öne çıkan katkılarından biri, otonom bir Büyük Dil Modeli kullanılarak Grad-CAM ısı haritalarının denetlenmesi ve kısayol öğrenme eğilimlerinin otonom olarak tespit edilmesidir. "Yapay Zekayı Denetleyen Yapay Zeka" olarak adlandırılan bu yaklaşımla tespit edilen hatalı odaklanma sorunlarını kökünden çözmek için OpenCV tabanlı hücresel segmentasyon algoritmaları tasarlanmıştır. Öte yandan, farklı donanımlardan alınan görüntülerdeki alan kayması problemi, modeli yeniden eğitmeye gerek kalmadan sadece çıkarım zamanında uygulanan Reinhard renk normalizasyonu ve test-zamanı veri çoğaltma (TTA) ardışık düzeni ile aşılmıştır.

Elde edilen sonuçlara göre geliştirilen model, bağımsız TestA veri setinde %98.53 genel doğruluğa ve Nötrofil tespitinde %99.94 kesinlik değerine ulaşmıştır. Eğitim aşamasında hiç görülmeyen ve farklı donanımla elde edilen TestB veri setindeki performans ise, uygulanan adaptasyon yöntemleriyle +32.09 puan artırılarak %89.05'e taşınmış, böylece sistemin yüksek genelleme yeteneği ve klinik güvenilirliği kanıtlanmıştır. Çalışma yalnızca akademik bir modelleme başarısı ile sınırlı kalmamış; bir Jupyter defterinden çıkarılarak Clinical MLOps prensipleriyle Python tabanlı bir RESTful web servisine dönüştürülmüştür. Dış sistemlerden görüntü kabul etme, girdi doğrulama, hata yönetimi ve işlem loglama yeteneklerine sahip olan bu sistem, 200-350 ms gibi gerçek zamanlı klinik kararlara uygun yanıt süresiyle akademik araştırma çıktısı, endüstriyel standartlarda çalışan bir mühendislik ürününe dönüştürülmüştür.

1 Giriş

Teknolojideki üstel büyüme ve hesaplama gücündeki artış, sağlık sektöründe teşhis ve tedavi süreçlerinin dijitalleşmesini bir tercih olmaktan çıkarıp zorunluluk haline getirmiştir. Özellikle Yapay Zeka (YZ) ve Bilgisayarlı Görü (Computer Vision) alanındaki gelişmeler, tıbbi görüntülerin otomatik analizinde yeni olanaklar sunmaktadır. Tıbbi laboratuvar süreçlerinin en temel ve yoğun bileşenlerinden biri olan hematolojik analizler, hastalıkların erken teşhisinde kritik bir rol oynamaktadır. Kanın hücresel bileşenlerinin doğru tanımlanması, sayılması ve sınıflandırılması; enfeksiyonlardan alerjilere, anemiden lösemi gibi malign hastalıklara kadar geniş bir yelpazedeki patolojilerin belirlenmesinde hekimlere yol gösteren en önemli veridir.

Bu proje, geleneksel manuel inceleme yöntemlerinin yarattığı operasyonel darboğazları aşmak, laboratuvar süreçlerini modernize etmek ve tanı doğruluğunu maksimize etmek amacıyla; Beyaz Kan Hücrelerinin (WBC) sınıflandırılmasını otomatikleştiren, derin öğrenme tabanlı ve uçtan uca entegre edilebilir yenilikçi bir yazılım sistemi geliştirmeyi hedeflemektedir.

1.1 Problemin Tanımı ve Mevcut Durum

Kan, vücudun homeostazını sağlayan, oksijen taşıyan ve bağışıklık sisteminin temel savunma hattını oluşturan hayati bir dokudur. Periferik kan yayma (Peripheral Blood Smear) testleri, bu dokunun hücresel morfolojisini mikroskopik düzeyde incelemek için kullanılan "altın standart" tanı yöntemidir. Bu incelemede, özellikle lökositler olarak bilinen Beyaz Kan Hücrelerinin (WBC) analizi hayati önem taşır. WBC'ler, morfolojik yapılarına ve işlevlerine göre beş ana alt tipe ayrılır: Akut bakteriyel enfeksiyonlara yanıt veren Nötrofil, paraziter enfeksiyon ve alerjik reaksiyonlarda artış gösteren Eozinofil, inflamatuvar yanıtlarda rol alan Bazofil, viral enfeksiyonlara karşı savunma geliştiren Lenfosit ve fagositoz yeteneğiyle patojenleri yok eden Monosit.

Her bir hücre tipinin kandaki oransal dağılımı ve yapısal bozulmaları, spesifik bir hastalığın parmak izi niteliğindedir [1]. Ancak günümüzde bu kritik analizler, halen büyük ölçüde uzman hematologlar veya laboratuvar teknisyenleri tarafından mikroskop başında manuel olarak gerçekleştirilmektedir. Bu geleneksel yöntem, modern tıbbın hız ve standartlaşma gereksinimlerini karşılamakta yetersiz kalmakta ve beraberinde ciddi mühendislik problemleri getirmektedir:

1.1.1 Zaman ve iş gücü maliyeti

Bir kan örneğinin preparatının hazırlanması, mikroskop altında taranması, ilgili hücrelerin bulunması ve yüzlerce hücrenin tek tek sayılarak sınıflandırılması, uzman bir personel için ortalama 15-20 dakika süren emek-yoğun bir işlemdir [2]. Günde yüzlerce, hatta binlerce

örneğin işlendiği yoğun hastanelerde bu durum, ciddi bir iş gücü kaybına neden olmakta ve hastaların test sonuçlarını bekleme sürelerini ciddi ölçüde uzatmaktadır.

1.1.2 İnsan faktörüne bağlı hata riski

Mikroskobik inceleme, yüksek düzeyde görsel dikkat, deneyim ve konsantrasyon gerektirir. Ancak insan doğası gereği, uzmanın yorgunluğu, o anki dikkat seviyesi, stres faktörleri veya deneyim eksikliği, teşhisin doğruluğunu doğrudan etkileyebilmektedir. Literatürdeki çalışmalar, manuel incelemelerde "gözlemciler arası" (inter-observer) ve "gözlemci içi" (intra-observer) tutarlılığın düşük olabildiğini, aynı örneğe bakan iki farklı uzmanın farklı sonuçlar raporlayabildiğini göstermektedir [3]. Özellikle Monosit ve Lenfosit gibi morfolojik olarak birbirine benzeyen hücrelerin ayrımında insan gözü yanılmaya açıktır.

1.1.3 Standardizasyon eksikliği

Farklı laboratuvarlarda kullanılan mikroskopların optik kalibrasyonu, boyama (Giemsa/Wright) tekniklerindeki kimyasal konsantrasyon farklılıkları ve ortam ışığı gibi çevresel faktörler, görüntü kalitesinde varyasyonlara neden olmaktadır. Standart bir dijital çözümün yokluğu, bu varyasyonların teşhis sürecine gürültü (noise) olarak yansımaya ve sağlık hizmetlerinde kalite standartlarının uygulanmasının zorlaşmasına neden olmaktadır.

1.2 Motivasyon

Bu projenin temel amacı; manuel WBC sınıflandırma sürecindeki zaman kaybı ve hata riskini minimize eden, insan performansının üzerinde doğruluk oranlarına sahip, otonom bir "Dijital Patoloji Asistanı" geliştirmektir. Proje kapsamında benimsenen çözüm yaklaşımı, sadece akademik bir sınıflandırma başarısı elde etmekle sınırlı değildir. Mühendislik tasarımı perspektifiyle asıl hedef; literatürde başarısı kanıtlanmış derin öğrenme modellerini temel alıp, bunları özgün algoritmalarla güçlendirerek gerçek dünya senaryolarında (Hastane Bilgi Sistemleri - HBS) kullanılabilecek, ölçeklenebilir bir Web Servisi (API) mimarisine dönüştürmektir.

Bu doğrultuda projenin teknik hedefleri ve çözüm metodolojisi şu temeller üzerine kurulmuştur:

1.2.1 Derin öğrenme ve transfer learning stratejisi

Hücrelerin karmaşık morfolojik özelliklerini (çekirdek lob yapısı, sitoplazma granülasyonu, kromatin yoğunluğu vb.) otomatik olarak öğrenebilen DenseNet121 mimarisi temel alınmıştır. Modelin odaklanma yeteneğini artırmak için projeye özgü "Attention Block" (Dikkat Mekanizmaları) ve öğrenme kapasitesini artıran

”MedSwish” aktivasyon fonksiyonları geliştirilerek hibrit bir mimari tasarlanmıştır.

1.2.2 Görüntü standardizasyonu (preprocessing)

Farklı cihazlardan alınan görüntülerin yarattığı varyasyonları elimine etmek için, literatürdeki standart yöntemlerin ötesine geçen, renk normalizasyonu ve seçici keskinleştirme (selective sharpening) adımlarını içeren özgün bir ”Medical Enhanced Filter” algoritması geliştirilmiştir.

1.2.3 Sistem entegrasyonu ve servis mimarisi

Eğitilen modeli izole bir Python betiği olmaktan çıkarıp, Python Flask çatısı kullanılarak endüstriyel standartlarda bir RESTful API servisi haline getirmek projenin nihai amacıdır. Bu servis; dış sistemlerden veri kabul etme, güvenlik doğrulama, yük dengeleme ve loglama yeteneklerine sahip tam bir ”backend” çözümü olarak tasarlanmıştır.

1.3 Projenin Özgün Değeri ve Beklenen Katkıları

Beyaz kan hücresi sınıflandırması üzerine literatürde yapılan çalışmaların büyük çoğunluğu, genellikle modelin sadece doğruluk (accuracy) metriğini artırmaya odaklanan teorik araştırmalardır. Ancak bu modellerin klinik ortamda nasıl dağıtılacağı, farklı cihazlardan gelen görüntülere nasıl tepki vereceği ve son kullanıcıya nasıl ulaştırılacağı konuları genellikle geri planda kalmaktadır. Bu projenin temel özgünlüğü, akademik bir araştırma çıktısını, endüstriyel standartlarda kullanılabilecek, ölçeklenebilir ve güvenilir bir mühendislik ürününe dönüştürme vizyonunda yatmaktadır. Projenin literatüre, sektöre ve mühendislik disiplinine sağladığı katkılar aşağıda detaylandırılmıştır.

1.3.1 Literatüre Özgün Algoritmik Katkıları

Bu çalışmada, var olan derin öğrenme mimarileri doğrudan kullanılmak yerine, tıbbi görüntülerin spesifik zorluklarını aşmak üzere tasarlanmış yeni mekanizmalarla güçlendirilmiştir. Bu yaklaşım, projenin sadece bir uygulama projesi olmasının ötesine geçerek literatüre teorik katkı sunmasını sağlamıştır.

Standart Evrişimli Sinir Ağları (CNN), görüntünün tamamını eşit ağırlıkla işleme eğilimindedir. Ancak mikroskobik görüntülerde arka plandaki eritrositler, lekeler veya boyama hataları gürültü oluşturabilir. Bu projede geliştirilen ”Channel” ve ”Spatial” dikkat mekanizmalarını birleştiren özgün WBC attention blok sayesinde, modelin doğrudan ilgili lökosit hücresine odaklanması sağlanmış ve sınıflandırma başarısı

artırılmıştır.

Derin ağlarda yaygın kullanılan ReLU aktivasyon fonksiyonu, negatif değerleri sıfırlayarak bilgi kaybına ("Dying ReLU" problemi) yol açabilmektedir. Tıbbi görüntülerdeki ince detayların kaybolmaması adına, bu projede öğrenilebilir ve parametrelerine sahip, negatif değerlerde de hafifçe aktif kalarak bilgi akışını koruyan "MedSwish" fonksiyonu geliştirilmiş ve model mimarisine entegre edilmiştir.

1.3.2 Endüstriyel Standartlarda Sistem Mimarisi

Akademik çalışmaların çoğu Jupyter Notebook ortamında kalmakta ve gerçek dünya entegrasyonu sunmamaktadır. Bu proje ise "Model-as-a-Service" (MaaS) yaklaşımını benimseyerek, eğitilen modeli yaşayan bir yazılım sistemine dönüştürmüştür.

Eğitilen model, Python Flask çatısı kullanılarak platform bağımsız bir Web Servisi haline getirilmiştir. Bu yapı, geliştirilen yapay zeka sisteminin Hastane Bilgi Sistemleri (HBS), Laboratuvar Bilgi Yönetim Sistemleri (LBYS) veya mobil uygulamalar ile herhangi bir uyum sorunu yaşamadan haberleşebilmesine olanak tanımaktadır.

Sadece doğru tahmin yapmak yeterli değildir; sistemin hatalı verilere karşı da dirençli olması gerekir. Geliştirilen mimaride, sunucuya gönderilen veriler işlenmeden önce sıkı bir girdi doğrulama (input validation) sürecinden geçirilir. Ayrıca, olası sistem hataları ve işlem kayıtları detaylı bir şekilde loglanarak sistemin izlenebilirliği ve bakım kolaylığı sağlanmıştır.

1.3.3 Veri İşleme ve Genelleme Yeteneği

Yapay zeka modellerinin en büyük sorunu, eğitim verisine aşırı uyum sağlayıp (overfitting) farklı kaynaklardan gelen verilerde başarısız olmasıdır. Bu proje, geliştirdiği hibrit yöntemlerle bu soruna çözüm üretmiştir.

Farklı laboratuvarlardaki mikroskopların ışık ve renk kalibrasyonları farklılık gösterebilir. Proje kapsamında geliştirilen renk normalizasyonu, CLAHE ve seçici keskinleştirme adımlarını içeren özgün filtreleme algoritması, bu donanım varyasyonlarını minimize ederek modelin her koşulda standart performans göstermesini sağlamaktadır.

Periferik yayma örneklerinde Nötrofil ve Lenfositler çok sık görülürken, Bazofil gibi hücreler nadir bulunur. Standart eğitim yöntemleri, modelin çoğunluk sınıflara önyargılı olmasına neden olabilir. Bu projede uyarlanan "WBC Focal Loss" fonksiyonu, modelin kolay örnekler yerine zor ve azınlıkta kalan örneklerle odaklanmasını sağlayarak nadir hastalıkların tespit başarısını artırmıştır.

1.3.4 Sosyal Etki ve Klinik Kullanılabilirlik

Projenin nihai amacı, teknolojiyi sağlık çalışanlarının hizmetine sunarak toplumsal fayda yaratmaktır.

Manuel incelemede 15-20 dakika sürebilen bir analiz süreci, geliştirilen sistem sayesinde milisaniyeler mertebesine indirilmiştir. Bu hız artışı, özellikle acil servislerde ve yoğun hasta akışı olan hastanelerde doktorların karar verme sürecini hızlandırarak hasta mağduriyetlerini azaltma potansiyeline sahiptir.

Yorgunluk, dikkat dağınıklığı veya deneyim eksikliği gibi insan faktörlerinden etkilenmeyen bu sistem, "İkinci Görüş" (Second Opinion) olarak görev yaparak yanlış teşhis risklerini minimize eder ve sağlık hizmetlerinde standardizasyonu sağlar.

2 Literatür Taraması

Beyaz kan hücrelerinin mikroskopik görüntülerden otomatik tespiti ve sınıflandırılması, biyomedikal görüntü işleme alanında uzun süredir çalışılan bir problemdir. Literatürdeki çalışmalar, sadece model başarısı ile sınırlı kalmayıp, son yıllarda modellerin dağıtımı, güvenilirliği ve sistem mimarileri üzerine yoğunlaşmıştır. Bu bölümde konuyla ilgili çalışmalar detaylıca incelenmiştir.

2.1 Geleneksel Görüntü İşleme Yöntemleri

Erken dönemde hücre sınıflandırılmasında genelde renk, şekil, doku ve geometrik özelliklerin elle çıkarılmasına dayalı yöntemler kullanılmıştır.

Su ve arkadaşları [4], geliştirdikleri segmentasyon yaklaşımıyla hücrelere özel nitelikleri elde etmiş ve bunları yapay sinir ağları ile sınıflandırarak %99.11 seviyesinde yüksek başarı elde etmişlerdir.

Elen ve Turan [5], mikroskopik görüntülerden istatistiksel ve geometrik özellikleri çıkararak karar ağaçları, en yakın komşu ve destek vektör makineleri gibi algoritmaları kıyaslamış; en yüksek başarıyı %95 ile çoklu lojistik regresyon kullanarak elde etmişlerdir.

Banik ve arkadaşları [6], ise çekirdek segmentasyonu için K-means kümeleme kullanmış ve %98.61 sonucunu almışlardır.

Ancak Scotti [3] gibi araştırmacıların da belirttiği üzere, bu yöntemler ışıktandırma, boyama farklılıkları ve gürültü gibi çevresel etkenlere karşı çok hassastır. Bu projenin ilk aşamasında gerçekleştirilen OpenCV denemeleri de (HSV ve Otsu Eşikleme), 5 farklı hücre tipini ayırt etmekte yetersiz kalarak bu literatür bilgisini doğrulamıştır.

2.2 Derin Öğrenme Tabanlı Yöntemler

Shahin ve ark. [7], "WBCsNet" adını verdikleri bir CNN mimarisi ile %96.1 doğruluğa ulaşmışlardır. Ayrıca transfer öğrenme yöntemlerini kullanan Bozkurt [8], DenseNet121 gibi modellerle %94 ve üzeri başarı raporlamıştır.

Sınıflandırma dışında hücre yeri belirleme konusunda da YOLO mimarileri öne çıkmaktadır. Shah ve ark. [9], YOLOv3 modelinin R-CNN ve SSD gibi rakiplerinden daha hızlı olduğunu ve %99 doğruluğa ulaştığını belirtmişlerdir. Kutlu ve arkadaşları [10] ise R-CNN kullanarak %100 başarıya ulaşabilmişlerdir.

2.3 Referans Çalışma ve Projenin Konumu

Bu projede temel alınan Akalın ve Yumuşak'ın çalışmasında [11], Raabin-WBC veri seti üzerinde YOLOv5 ve Detectron2 modelleri kıyaslanmıştır. Çalışma, bu iki modelin güçlü yanlarını birleştiren bir hibrit yapı önererek test veri setinde %98 doğruluğa ulaşmıştır. Bu tasarım projesi, literatürde var olan bu başarılı modellerin genellikle

araştırma seviyesinde kalmasından yola çıkarak, bu akademik başarıyı bir son kullanıcı ürününe dönüştürmeye odaklanmıştır.

2.4 Sağlıkta Yapay Zeka Modellerinin Dağıtımı ve Karşılaşılan Zorluklar

Akademik çalışmalarda doğruluk oranlarına sahip birçok derin öğrenme modeli geliştirilmiş olsa da, bu modellerin klinik ortama dahil edilmesi ve sürdürülebilirliği konusunda ciddi boşluklar bulunmaktadır. Esmailzadeh [12], sağlık kuruluşlarında yapay zeka dağıtımının önündeki en büyük engellerden birinin ”araştırmadan üretime geçiş süresi” (time-to-production) olduğunu belirtmektedir. Geliştirilen modellerin izole birer araştırma çıktısı olarak kalması yerine, mevcut hastane bilgi sistemlerine (HBS) ve elektronik sağlık kayıtlarına (EHR) dahil edilebilir yapıda olması gerekmektedir.

Zhang ve ark. [13], son on yılda odak noktasının ”model geliştirmekten” ”veri merkezli dağıtım” kaydığını vurgulamaktadır. Modellerin klinik ortamda anlık tahminler yapabilmesi için verinin verimli bir şekilde modele taşınması ve modelin bir servis olarak sunulması kritik ölçüde önemlidir. Bu bağlamda, Esteva ve ark. [14], derin öğrenme modellerinin başarısının sadece algoritmik güce değil, aynı zamanda verinin işlenmesi, taşınması ve güvenliğinin sağlanması gibi sistem tasarımı unsurlarına bağlı olduğunu ortaya koymuştur.

Jackson ve ark. [15], ”Agile Deployment” kavramını sağlık bilişimine uyarlayarak, modellerin sürekli entegrasyon (CI/CD) prensipleriyle, API tabanlı mikroservisler olarak sunulmasının, sistemin bakımı ve güncellenebilirliği açısından en sürdürülebilir yöntem olduğunu savunmaktadır.

2.5 Tıbbi Modellerde Güvenilirlik ve Belirsizlik Yönetimi

Derin öğrenme modellerinin klinik ortamda dağıtımı sırasında karşılaşılan bir diğer kritik sorun, klasik modellerin belirsizlik konusundaki yetersizliğidir. Abdullah ve ark. [16], klasik derin öğrenme modellerinin (CNN gibi), tahminlerinde hata yapsalar dahi sonuçtan aşırı emin olma eğiliminde olduklarını belirtmektedir. Tıbbi teşhis gibi hatanın maliyetinin yüksek olduğu alanlarda, modelin sadece ”bu kanserdir” demesi yetmez; aynı zamanda ”bu kararımdan %40 emin değilim” diyerek belirsizliği de raporlaması gerekir.

Bu bağlamda, Bayesian Derin Öğrenme (BDL) yaklaşımları, model parametrelerine olasılık dağılımları ekleyerek hem veriden kaynaklı hem de modelden kaynaklı belirsizlikleri ölçülebilir hale getirmektedir [16]. Bu proje kapsamında geliştirilen prototip şu an için klasik CNN mimarisini kullansa da, oluşturulan API mimarisi gelecekte bu tür güvenilir yapay zeka modellerinin entegrasyonuna açık şekilde tasarlanmıştır.

2.6 Tıbbi Görüntüleme ve Sağlık Verilerinde Web Servis Yaklaşımları

Geleneksel tıbbi görüntü analiz sistemleri genellikle yerel makinelerde çalışan masaüstü yazılımlar olarak tasarlanmıştır. Fakat son yıllarda, işlem gücünü merkezi sunuculara taşıyan ve erişilebilirliği artıran web tabanlı mimarilere ve REST API çözümlerine doğru bir yönelim görülmektedir.

Aribisala ve Olabanjo [17], geliştirdikleri MIPAR sistemi ile tıbbi görüntü analiz araçlarının "Hizmet Olarak Yazılım" (SaaS) modeliyle web üzerinden sunulmasının, yerel kaynak kısıtlarını aştığını ve uzmanlar arası işbirliğini kolaylaştırdığını belirtmişlerdir. Aynı şekilde, Russell ve ark. [18], "The Cancer Imaging Archive" (TCIA) gibi devasa tıbbi görüntü veri setlerine erişim için REST API tabanlı bir istemci geliştirmişlerdir.

Görüntü işleme görevlerinin bir API servisi olarak sunulması yaklaşımı, sadece veri erişimiyle sınırlı değildir. Balga [19], geliştirdiği takip sisteminde, kameradan alınan görüntülerin işlenmek üzere bir REST API servisine aktarıldığı bir mimari önermiştir. Chete ve Omorokunwa [20], ise işlem gücü gerektiren görüntü sıkıştırma algoritmalarını bir REST API arkasında sunarak verimliliği kanıtlamıştır. Sağlık verilerinin yönetimi tarafında ise Roziqin ve ark. [21], hastaneler arası tıbbi kayıt paylaşımı için RESTful API mimarisini kullanmış ve bu yapının uyumluluğu sağladığını vurgulamıştır.

2.7 Nesne Tespiti Mimarilerinin Evrimi ve Tıbbi Görüntülemede YOLO Modelleri

Beyaz kan hücrelerinin tespiti gibi problemlerde, sadece sınıflandırma değil, nesnenin konumunun belirlenmesi de kritik öneme sahiptir. Sapkota ve ark. [22], YOLO mimarisinin YOLOv1'den en güncel YOLOv12 sürümüne kadar olan evrimini incelemiş ve bu modellerin gerçek zamanlı nesne tespitindeki başarısının tıbbi teşhis sistemlerinde kritik rol oynadığını belirtmiştir. Ali ve Zhang [23], YOLO'nun küçük nesneleri tespit etme konusundaki tarihsel zorluklarının, yeni versiyonlardaki mimari iyileştirmelerle aşıldığını vurgulamaktadır.

Ragab ve ark. [24] tarafından yapılan sistematik incelemede, 2018-2023 yılları arasındaki tıbbi nesne tespiti çalışmaları analiz edilmiş ve YOLO tabanlı modellerin üstün performans gösterdiği raporlanmıştır. Benzer şekilde, Saraei ve ark. [25], modern YOLO varyasyonlarının tıbbi görüntülemede %98.6 ile %99.5 arasında değişen ortalama kesinlik değerlerine ulaştığını ortaya koymuştur. Soni ve Rai [26] ise 80 farklı çalışmayı inceleyerek, YOLO algoritmalarının kan hücrelerinin lokalizasyonu gibi görevlerdeki etkinliğini doğrulamıştır.

3 Materyal ve Metot

Bu bölümde; projenin gerçekleştirilmesinde kullanılan donanım ve yazılım altyapısı, Raabin-WBC veri setinin yapısı, geliştirilen özgün ön işleme ve model bileşenleri ile Flask tabanlı API mimarisi sunulmaktadır.

3.1 Materyal ve Geliştirme Ortamı

Yapay zeka modellerinin eğitimi, yüksek hesaplama gücü ve matris operasyonlarında performans gerektirdiğinden, proje geliştirme süreci güçlü bir donanım altyapısı üzerinde yürütülmüştür. Model eğitimi için NVIDIA GPU hızlandırması kullanılırken, sistem entegrasyonu ve API servisleri Python ekosistemi üzerinde geliştirilmiştir.


Projede kullanılan teknik envanter Tablo 1’de sunulmuştur.

Tablo 1: Teknik Envanter

Bileşen Tipi	Teknoloji / Araç	Sürüm / Özellik
Donanım	GPU	NVIDIA GeForce RTX 4070 Ti SUPER
Donanım	CPU	Intel Core i7 / AMD Ryzen
Yazılım	İşletim Sistemi	Windows 11
Dil	Python	3.9+
Kütüphane	TensorFlow	2.10.0
Kütüphane	Flask	2.3.x
Kütüphane	OpenCV	4.8.x
IDE	VS Code	Latest

3.2 Veri Kümesi

Projede, beyaz kan hücrelerinin sınıflandırılması amacıyla Tahran Üniversitesi tarafından yayınlanan ve etik kurulu onayı alınmış açık kaynaklı Raabin-WBC veri seti kullanılmıştır [27].



Şekil 1: Raabin-WBC veri setinden örnek görüntüler

3.2.1 Veri yapısı

Veri seti, Giemsa boyama tekniği ile hazırlanmış periferik kan yayma görüntülerinden oluşmaktadır. Görüntüler hem akıllı telefon kameraları (Samsung S5) hem de profesyonel mikroskop kameraları ile elde edilmiştir. Bu çeşitlilik, geliştirilen modelin farklı donanımlara karşı dayanıklı (robust) olmasını zorunlu kılmıştır.

3.2.2 Sınıf dağılımı


Veri seti 5 ana sınıftan oluşmaktadır: Nötrofil (Neutrophil), Eozinofil (Eosinophil), Bazofil (Basophil), Lenfosit (Lymphocyte) ve Monosit (Monocyte). Veri setinde Nötrofil ve Lenfosit gibi yaygın hücreler çoğunlukta, Bazofil gibi nadir hücreler azınlıktadır. Bu dengesizliği yönetmek için eğitim aşamasında "Focal Loss" stratejisi benimsenmiştir.

3.2.3 Veri ayrımı


Train (eğitim): ~12.000 görüntü (Modelin öğrenmesi için)

TestA (bağımsız test): ~4.339 görüntü (Nihai model performans değerlendirmesi için)

TestB (genelleme): Tamamen farklı bir cihazdan alınan görüntüler (Gerçek dünya testi için).



Şekil 2: Veri Seti Sınıf Dağılım-1



Şekil 3: Veri Seti Sınıf Dağılımı-2

3.3 Yöntem

Projede, geleneksel görüntü işleme yöntemlerinin (eşikleme, el yapımı öz nitelik çıkarımı vb.) hücrelerin yapısal çeşitliliklerine karşı yetersiz kalması nedeniyle, uçtan uca öğrenme (end-to-end learning) yeteneğine sahip Derin Öğrenme metodolojisi benimsenmiştir. Yöntem üç ana temel üzerine kuruludur:

3.3.1 Geliştirilen Özgün Ön İşleme: Medical Enhanced Filter

Literatürdeki standart filtreleme yöntemlerinin (CLAHE [28, 29], Gaussian keskinleştirme, bilateral filtreleme [30]) tek başına periferik yayma görüntüleri için yetersiz kalması üzerine, projeye özgü beş aşamalı hibrit bir filtreleme algoritması olan **Medical Enhanced Filter (MEF)** geliştirilmiştir.

Adım 1 — Yüzdelik Tabanlı Renk Normalizasyonu. Farklı cihazlardan gelen görüntülerin piksel yoğunluklarını %2–%98 yüzdelik aralığına çekerek standartlaştırır. Bu adım, değişen mikroskop pozlama koşullarından kaynaklanan sistematik parlaklık farklılıklarını giderir:

$$I'_i = \frac{I_i - P_2^{(i)}}{P_{98}^{(i)} - P_2^{(i)}} \cdot 255, \quad i \in \{R, G, B\} \quad (1)$$

Adım 2 — LAB Uzayında CLAHE. Görüntü RGB'den LAB renk uzayına dönüştürülür ve yalnızca L (Aydınlık) kanalına Contrast Limited Adaptive Histogram Equalization (CLAHE) [28] uygulanır. Bu yaklaşım, renk kanallarını bozulmadan korurken hücre yapısını belirginleştirir. Tek tile boyutu yerine **çift ölçekli CLAHE** kullanılmıştır: küçük tile (4×4) çekirdek granülasyonu gibi ince yapılar için, büyük tile (8×8) ise sitoplazma gibi geniş bölgeler için ayrı ayrı uygulanır. İki sonuç, Canny kenar haritasına dayalı adaptif ağırlıkla birleştirilir:

$$L_{\text{fused}} = L_{\text{fine}} \cdot (0,5 + 0,5 w_e) + L_{\text{coarse}} \cdot (0,5 - 0,5 w_e) \quad (2)$$

burada $w_e \in [0, 1]$ kenar haritasının Gauss yumuşatmasıdır.


Adım 3 — Kenar Korumalı Bilateral Filtreleme. Bilateral filtre [30], hücre kenarlarını korurken sitoplazma içindeki gürültüleri temizler. Filtre parametreleri ($d = 9$, $\sigma_c = 65$, $\sigma_s = 65$) WBC görüntüleri üzerinde deneysel olarak belirlenmiştir.

Adım 4 — Morfolojik Çekirdek Vurgulama. Periferik yayma görüntülerinde çekirdek morfolojisi (lob yapısı, kromatin yoğunluğu) WBC sınıflandırmasının birincil belirleyicisidir. Eliptik yapılandırma elemanlarıyla hesaplanan iç ($k_{3 \times 3}$) ve dış ($k_{7 \times 7}$) morfolojik gradyanlar birleştirilerek çekirdek sınırları vurgulanmaktadır:

$$G = 0,6 (\text{dilate}(I_g, k_3) - \text{erode}(I_g, k_3)) + 0,4 (\text{dilate}(I_g, k_7) - \text{erode}(I_g, k_7)) \quad (3)$$

Adım 5 — Seçici Ağırıklı Keskinleştirme. Kenar tespiti yapılarak yalnızca hücre sınırları keskinleştirilir; düzgün (non-edge) bölgeler korunmaktadır. Canny ve Laplacian-of-Gaussian (LoG) kenar haritaları birleştirilerek adaptif ağırlık (w_e) üretilir:


$$I_{\text{out}} = I \cdot (1 - 0,35 w_e) + I_{\text{sharp}} \cdot 0,35 w_e \quad (4)$$




Şekil 4: Preprocess Akış Diyagramı

Kod Bloğu 1 Özgün Medical Enhanced Filter (MEF)

```
1 def medical_enhanced(image):
2     # Adim 1: Yuzdelik Tabanlı Renk Normalizasyonu
3     normalized = image.copy().astype(np.float32)
4     for i in range(3):
5         channel = normalized[:, :, i]
6         p2, p98 = np.percentile(channel, (2, 98))
7         normalized[:, :, i] = np.clip(
8             (channel - p2) / (p98 - p2 + 1e-6) * 255, 0, 255)
9     normalized = normalized.astype(np.uint8)
10
11     # Adim 2: LAB uzayında Çift Ölçekli CLAHE
12     lab = cv2.cvtColor(normalized, cv2.COLOR_RGB2LAB)
13     l, a, b = cv2.split(lab)
14     clahe_fine = cv2.createCLAHE(clipLimit=3.0,
15     ↪ tileGridSize=(4, 4))
16     clahe_coarse = cv2.createCLAHE(clipLimit=2.0,
17     ↪ tileGridSize=(8, 8))
18     edges = cv2.Canny(l, 30, 100).astype(np.float32) / 255.0
19     w_e = cv2.GaussianBlur(edges, (11, 11), 3)
20     l_fused = (clahe_fine.apply(l) * (0.5 + 0.5*w_e)
21     ↪ + clahe_coarse.apply(l) * (0.5 - 0.5*w_e))
22     enhanced = cv2.cvtColor(
23     ↪ cv2.merge([l_fused.astype(np.uint8), a, b]),
24     ↪ cv2.COLOR_LAB2RGB)
25
26     # Adim 3: Bilateral Filtreleme
27     enhanced = cv2.bilateralFilter(enhanced, 9, 65, 65)
28
29     # Adim 4: Morfolojik Çekirdek Vurgulama
30     gray = cv2.cvtColor(enhanced, cv2.COLOR_RGB2GRAY)
31     k3, k7 = (cv2.getStructuringElement(cv2.MORPH_ELLIPSE, (s,
32     ↪ s)))
33     for s in (3, 7))
34     G = 0.6*(cv2.dilate(gray,k3)-cv2.erode(gray,k3)) + \
35     ↪ 0.4*(cv2.dilate(gray,k7)-cv2.erode(gray,k7))
36     enhanced = np.clip(
37     ↪ enhanced*(1 + 0.2*G[...,None]/255.), 0,
38     ↪ 255).astype(np.uint8)
39
40     # Adim 5: Seçici Ağırlıklı Keskinleştirme (Canny + LoG)
41     edges_c = cv2.Canny(gray, 40, 120)
42     log = np.abs(cv2.Laplacian(
43     ↪ cv2.GaussianBlur(gray, (3,3),0), cv2.CV_16S, ksize=3))
44     _, edges_l = cv2.threshold(log.astype(np.uint8), 10, 255,
45     ↪ cv2.THRESH_BINARY)
46     w_e = cv2.GaussianBlur(
47     ↪ cv2.bitwise_or(edges_c,
```



Şekil 5: Preprocess Karşılaştırma Görseli



Şekil 6: Filtre Karşılaştırması

3.3.2 Transfer Learning Omurga Seçimi: Karşılaştırmalı Analiz

Uygun omurga mimarisini belirlemek amacıyla derin öğrenme ve transfer learning literatüründe yaygın kullanılan beş model [31] aynı koşullar altında karşılaştırmalı olarak değerlendirilmiştir. Karşılaştırmada tüm modeller aynı ön işleme pipeline'ı (MEF), aynı sınıflandırma başlığı ve iki aşamalı eğitim protokolüyle eğitilmiştir.

Karşılaştırılan modeller.

- **VGG16** [32]: Basit yığımlı evrişim mimarisi; 138 milyon parametre ile en ağır omurgadır.
- **ResNet50V2** [33]: Artık (residual) bağlantılar sayesinde derinleşen ağlarda gradyan sorununu giderir; 25 milyon parametre.
- **MobileNetV2** [34]: Ters artık (inverted residual) bloklar ile mobil sistemler için tasarlanmıştır; 3,4 milyon parametre.
- **EfficientNetB0** [35]: Bileşik ölçekleme (compound scaling) ile derinlik, genişlik ve çözünürlüğü eş zamanlı optimize eder; 5,3 milyon parametre.
- **DenseNet121** [36]: Her katmanın tüm önceki katmanların özellik haritalarına doğrudan eriştiği yoğun bağlantı (dense connectivity) yapısı, sınırlı veriyle yüksek parametre verimliliği sağlar. Bu özellik, tıbbi görüntüleme görevlerinde öne çıkmasının temel nedenidir [8].

Seçim kriterleri; doğrulama doğruluğu, Macro F1 skoru, toplam parametre sayısı ve çıkarım süresidir. Karşılaştırmalı analiz sonuçları Bölüm 4'te sunulmaktadır.

3.3.3 Model Mimarisi: DenseNet121 + Attention + MedSwish

Sınıflandırma başarısını maksimize etmek için temel (backbone) model olarak DenseNet121 [36] seçilmiştir. DenseNet'in seçilme nedeni, "Dense Connectivity" yapısı sayesinde VGG16 gibi modellere kıyasla çok daha az parametre (7,8 Milyon vs 138 Milyon) ile daha verimli öğrenme sağlamasıdır [36]. Standart mimari, aşağıdaki iki özgün bileşen ile güçlendirilmiştir:

WBC attention block (özgün dikkat mekanizması): Modelin, görüntünün arka planındaki ilgisiz alanlar yerine doğrudan lökosit hücresine odaklanmasını sağlayan modüldür. CBAM [37] mimarisinden ilham alınarak WBC görüntülerine özgü biçimde uyarlanmıştır.

Channel Attention: Hangi özellik haritalarının önemli olduğunu seçer.

Spatial Attention: Görüntünün "neresine" bakılması gerektiğini belirler.

MedSwish aktivasyon fonksiyonu: Yaygın kullanılan ReLU aktivasyon fonksiyonu negatif değerleri sıfırlayarak "Dying ReLU" sorununa yol açabilmektedir [38]. Tıbbi görüntülerdeki ince morfolojik detayların kaybolmaması amacıyla, öğrenilebilir α ve β parametrelerine sahip özgün bir aktivasyon fonksiyonu tasarlanmıştır. Swish [39] tabanlı bu fonksiyon negatif bölgede de hafifçe aktif kalarak bilgi akışını korur:

$$\text{Matematiksel Formül: } f(x) = x \cdot \sigma(\beta x) \cdot (1 + \alpha \cdot \tanh(x))$$

Kod Bloğu 2 WBC Attention Block Mimarisi

```
1 class WBCAttentionBlock(layers.Layer):
2     def build(self, input_shape):
3         # Channel Attention MLP
4         self.channel_dense1 = layers.Dense(input_shape[-1] //
5         ↪ 16, activation="relu")
6         self.channel_dense2 = layers.Dense(input_shape[-1])
7         # Spatial Attention Conv
8         self.spatial_conv = layers.Conv2D(1, kernel_size=7,
9         ↪ padding="same", activation="sigmoid")
10
11     def call(self, x):
12         x = self.channel_attention(x) # Kanallar arasi iliski
13         x = self.spatial_attention(x) # Mekansal odaklanma
14         return x
```

Kod Bloğu 3 MedSwish Fonksiyonu

```
1 class MedSwish(layers.Layer):
2     def call(self, x):
3         swish_part = x * tf.nn.sigmoid(self.beta * x)
4         enhancement = 1.0 + self.alpha * tf.nn.tanh(x)
5         return swish_part * enhancement
```

Tablo 2: Önerilen Model Mimarisi ve Parametre Özeti

Katman (Layer)	Çıktı Boyutu	Parametre Sayısı	Açıklama
Input	(224, 224, 3)	0	Ön işlenmiş görüntü girişi
DenseNet121	(7, 7, 1024)	7,037,504	Feature Extractor (Transfer Learning) [36]
WBC Attention	(7, 7, 1024)	132,259	Özgün Dikkat Bloğu (Channel + Spatial)
GlobalAvgPool	(1024)	0	Boyut azaltma
Dense 1	(512)	524,800	Sınıflandırma Katmanı 1
BatchNorm 1	(512)	2,048	Normalizasyon Katmanı
MedSwish 1	(512)	2	Özgün Aktivasyon (α, β)
Dropout 1	(512)	0	Aşırı öğrenme önleyici (%50)
Dense 2	(256)	131,328	Sınıflandırma Katmanı 2
BatchNorm 2	(256)	1,024	Normalizasyon Katmanı
MedSwish 2	(256)	2	Özgün Aktivasyon (α, β)
Output (Softmax)	(5)	1,285	Sonuç Katmanı (5 sınıf)
TOPLAM		7,830,252	~ 7.83 Milyon Parametre

Tablo 2’de görüldüğü üzere, modelin toplam parametre sayısı 7.83 Milyon seviyesindedir. Bu değer, benzer çalışmalarda sıkça kullanılan VGG16 modelinin (yaklaşık 138 Milyon parametre) %6’sı kadar bir büyüklüğe denk gelmektedir [32]. Parametre sayısının bu denli düşük tutulması, sistemin bellek (RAM) kullanımını minimize etmiş ve web servis yanıt süresinin 200ms seviyelerine inmesini sağlayan en önemli faktör olmuştur. Ayrıca, 7 milyon parametrenin (DenseNet121 omurgası) dondurularak (non-trainable) sadece özgün katmanların (791,212 parametre) eğitilmesi, modelin az veriyle yüksek genelleme yeteneğine ulaşmasını sağlamıştır.

3.3.4 Eğitim stratejisi ve kayıp fonksiyonu

Veri setindeki sınıf dengesizliğini yönetmek için standart Cross-Entropy yerine WBC Focal Loss fonksiyonu geliştirilmiştir [40]. Bu fonksiyon, modelin kolay sınıflandırdığı örneklerden ziyade, zorlandığı örneklere odaklanmasını sağlar:


$$\mathcal{L}_{\text{focal}} = - \sum_{c=1}^C \alpha_c (1 - p_c)^\gamma \log(p_c) \quad (5)$$

burada α_c sınıf ağırlığı, $\gamma = 2$ odaklama parametresi ve p_c tahmin olasılığıdır. Ek olarak Label Smoothing ($\varepsilon = 0,1$) ve Nötrofil/Lenfosit ayrımı için ikili yardımcı başlık (auxiliary head) kullanılmıştır.

Eğitim süreci İki Aşamalı (Two-Phase Training) olarak tasarlanmıştır:

Phase 1 (feature extraction): DenseNet ağırlıkları dondurulur, sadece son katmanlar yüksek öğrenme oranıyla eğitilir.

Phase 2 (fine-tuning): Tüm modelin kilidi açılır ve çok düşük öğrenme oranıyla ($1e-5$) ince ayar yapılır.



Şekil 7: DenseNet Eğitim Grafiği

3.4 Sistem Tasarımı ve API Mimarisi

Projenin temel amacı olan "kullanılabilir bir mühendislik ürünü" geliştirme hedefi doğrultusunda, eğitilen model Python Flask ile ölçeklenebilir bir RESTful API servisine dönüştürülmüştür [41].

Sistemin veri akış süreci şu şekildedir:

- İstek (Request): İstemci /predict uç noktasına HTTP POST ile görüntü gönderir.
- Doğrulama (Validation): Dosya formatı ve bütünlüğü kontrol edilir.
- Ön İşleme: Görüntü bellekte işlenerek modele uygun tensör formatına çevrilir.
- Tahmin (Inference): Model, sınıf ve güven skorunu üretir.
- Loglama: İşlem detayları api.log dosyasına kaydedilir.
- Yanıt (Response): Sonuç JSON formatında döner.


Yukarıda detaylandırılan sistem akışını ve tahminleme mantığını gerçekleştiren temel backend algoritması aşağıda sunulmuştur:

Algoritma 1 WBC Sınıflandırma Servisi Arka Plan İşleyişi

```
1: Girdi: Görüntü Dosyası ( $I_{raw}$ )
2: Çıktı: JSON formatında Sınıf Adı ve Güven Skoru

3: Başlat: Sunucuyu ayağa kaldır ve modeli belleğe yükle
4: Isınma (Warm-up): Boş bir girdi ile model grafiklerini hazırla

5: procedure PREDICT( $I_{raw}$ )
6:   if  $I_{raw}$  mevcut değil veya format geçersiz ise then
7:     return Hata 400 / 415 (Geçersiz İstek)
8:   end if
9:    $I_{img} \leftarrow Oku(I_{raw})$ 
10:   $I_{res} \leftarrow Resize(I_{img}, 224, 224)$ 
11:   $I_{enh} \leftarrow MedicalEnhancedFilter(I_{res})$  ▷ Özgün Filtreleme Adımı
12:   $Tahminler \leftarrow Model.Predict(I_{enh})$ 
13:   $Sinif, Skor \leftarrow ArgMax(Tahminler)$ 
14:   $Logla(IstekIP, Sinif, Skor)$  ▷ Sistem izlenebilirliği için
15:  return JSON( $\{Sinif, Skor, Detaylar\}$ )
16: end procedure
```



Şekil 8: Sistem Akış Şeması

3.5 Alan Kayması (Domain Shift) Yönetimi ve Çıkarım Zamanı (Inference) İyileştirmeleri

Sisteme entegre edilen LLM ajanının Grad-CAM haritalarında yaptığı otonom analizler sonucunda, modelin farklı donanımlardan (mikroskop/kamera) gelen görüntülerde renk ve doku varyasyonlarından etkilendiği tespit edilmiştir. Bu alan kaymasını (domain shift) gidermek amacıyla, model mimarisini değiştirmeden çıkarım (inference) aşamasında uygulanacak üçlü bir adaptasyon pipeline'ı tasarlanmıştır: Reinhard renk normalizasyonu [42], ikili yönlendirme (binary routing) ve hafif Test-Time Augmentation (TTA) [43].

3.6 Kısayol Öğrenmeye (Shortcut Learning) Karşı Dirençli Eğitim Mimarisi

Modelin hücre morfolojisi yerine arka plan gürültüsüne odaklanmasını (shortcut learning) önlemek için [44] `train_shortcut_resistant.py` betiği ile yeni bir eğitim stratejisi geliştirilmiştir. Bu kapsamda görüntülere eğitim sırasında %20 olasılıkla "Ön Plan Kırpma" (Foreground Cropping) ve %15 olasılıkla "Arka Plan Gürültü Enjeksiyonu" uygulanmıştır. Ayrıca, her epoch sonunda Grad-CAM [45] üzerinden otonom odak ölçümü yapan XAIFocusMonitor geri çağırım sınıfı ile odak hücre dışına kaydığında eğitim erken durdurulmaktadır.

Algoritma 2 Otonom Kısayol Öğrenme (Shortcut Learning) Denetim Algoritması

Girdi: I_{hedef} : Orijinal Hücre Görüntüsü, M : Eğitilmiş Sınıflandırma Modeli, L : LLM Ajanı

Çıktı: Denetim Raporu ve Adaptasyon Kararı

```
1:  $Tahmin, Guven \leftarrow M.predict(I_{hedef})$ 
2:  $H_{GradCAM} \leftarrow GradCAM\_Uret(M, I_{hedef}, Tahmin)$ 
3:  $I_{birlestirilmis} \leftarrow Overlay(I_{hedef}, H_{GradCAM})$ 
4:  $Rapor \leftarrow L.analyze(I_{birlestirilmis}, Tahmin)$ 
5: if  $Rapor.odak == "ArkaPlan"$  then
6:   Uyarı: Kısayol Öğrenme Tespit Edildi!
7:    $I_{yeni} \leftarrow ReinhardNormalizasyonu(I_{hedef})$ 
8:   Return  $M.predict(I_{yeni})$  ▷ Yeniden Değerlendirme
9: else
10:  Return "Güvenilir Odaklanma: Çekirdek/Sitoplazma"
11: end if
```

4 Araştırma Bulguları

Bu bölümde, geliştirilen yapay zeka destekli lökosit sınıflandırma sisteminin performansı detaylı bir şekilde analiz edilmiştir. Analizler; transfer learning omurga seçimi karşılaştırması, özgün mimari bileşenlerin etkisi, otonom LLM denetimi ile keşfedilen kısayol öğrenme (shortcut learning) problemi, çıkarım zamanı (inference) iyileştirmeleri ve nihai genelleme başarıları alt başlıklarında sunulmuştur.

4.1 Transfer Learning Omurga Karşılaştırması

Bölüm 3.3.2’de açıklanan karşılaştırmalı analiz kapsamında beş transfer learning omurgası aynı eğitim protokolüyle değerlendirilmiştir. Tablo 3, her modelin doğrulama doğruluğunu, Macro F1 skorunu, toplam parametre sayısını ve çıkarım süresini birlikte sunmaktadır.

Tablo 3: Transfer learning omurga mimarilerinin karşılaştırmalı analizi. Tüm modeller MEF ön işleme ve iki aşamalı eğitim protokolüyle eğitilmiştir. En iyi değerler **kalınlı** ile gösterilmiştir.

Model	Parametre (M)	Val. Acc. (%)	Macro F1	Çıkarım (ms)
VGG16 [32]	15,11	98,56	0,9724	18,1
ResNet50V2 [33]	24,75	98,17	0,9704	103,9
MobileNetV2 [34]	3,05	97,90	0,9577	96,0
EfficientNetB0 [35]	4,84	97,05	0,9418	185,4
DenseNet121 (yalın) [36]	7,70	98,89	0,9803	232,2
DenseNet121 + WBCAttention + MedSwish (önerilen)	7,83	98,53	0,9853	14,2

Tablo 3 incelendiğinde aşağıdaki gözlemler öne çıkmaktadır:

DenseNet121’in yoğun bağlantı yapısı, VGG16’ya kıyasla yaklaşık 18 kat daha az parametre ile rekabetçi doğruluk sergilemektedir. MobileNetV2 ve EfficientNetB0, düşük parametre sayısına karşın tıbbi görüntülerin ince morfolojik özelliklerini öğrenmede yetersiz kalmaktadır. ResNet50V2’nin artık bağlantıları derin ağlarda eğitim kararlılığı sağlasa da DenseNet121’in özellik yeniden kullanımı (feature reuse) mekanizması hematoloji görüntülemesinde avantaj sunmaktadır. **Önerilen hibrit mimari**, yalın DenseNet121’e kıyasla yalnızca 0,83 M ek parametre (WBC Attention: 132.259; MedSwish: 4 parametre) ile belirgin performans artışı sağlamaktadır. Bu bulgular, DenseNet121’in seçimini ampirik olarak desteklemekte ve özgün bileşenlerin bu temeli daha da güçlendirdiğini ortaya koymaktadır.

4.2 Özgün Mimari (MedSwish & Attention) ve Eğitim Süreci

Geleneksel derin öğrenme mimarilerinin mikroskobik görüntülerdeki zorlukları aşmada yetersiz kalması üzerine, proje kapsamında DenseNet121 omurgası temel alınarak özgün bir ağ tasarlanmıştır. Görüntüler ağa beslenmeden önce hücresel yapıları belirginleştiren ve cihaz farklılıklarını minimize eden Medical Enhanced Filter ön işleminden geçirilmiştir.

Ağ mimarisine entegre edilen özgün WBC Attention Block (Kanal ve Mekansal Dikkat Mekanizması), modelin görüntüdeki ilgisiz alanlar yerine doğrudan lökosit hücresine odaklanmasını sağlamıştır. Ayrıca standart aktivasyon fonksiyonlarının negatif değerlerdeki bilgi kaybı sorununu ("Dying ReLU") çözmek amacıyla, projeye özgü geliştirilen MedSwish aktivasyon fonksiyonu sisteme dahil edilmiştir. Bu özgün eklentilerle eğitilen model, doğrulama veri setinde yüksek bir teorik başarı göstermiştir.

4.2.1 Karmaşıklık matrisi (confusion matrix) analizi


Modelin sınıf bazlı ayırt etme performansını incelemek amacıyla önce tüm sınıfları içeren TestA doğrulama veri seti, ardından farklı donanım ile elde edilen TestB genelleme veri seti üzerinde analiz yapılmıştır. TestA veri seti üzerinde elde edilen sınıf bazlı performans metrikleri Tablo 4’de sunulmuştur:

Tablo 4: Sınıflandırma Raporu Tablosu

Hücre Sınıfı	Kesinlik (Precision)	Duyarlılık (Recall)	F1-Skoru	Örnek Sayısı
Nötrofil	0.9962	0.9868	0.9915	2660
Lenfosit	0.9865	0.9884	0.9874	1034
Bazofil	1.0000	1.0000	1.0000	89
Monosit	0.9372	0.9573	0.9471	234
Eozinofil	0.9265	0.9783	0.9517	322
Ağırlıklı Ortalama	0.9856	0.9853	0.9854	4339

Tablo 4 incelendiğinde; Nötrofil sınıfında %99.62 kesinlik değeriyle en yüksek güvenilirlik elde edilmiştir. Veri setindeki en az örneğe sahip nadir sınıf olan Bazofil sınıfında hem kesinlik hem duyarlılık değerinin %100.0 olması, sınıf dengesizliği probleminin başarıyla yönetildiğini kanıtlamaktadır. En düşük F1-Skoru Eozinofil sınıfında gözlemlenmiş olup bu durum, Eozinofil ile Nötrofil hücrelerinin sitoplazma granülasyonlarının morfolojik benzerliğinden kaynaklanmaktadır.

TestB veri seti yalnızca Lenfosit ve Nötrofil sınıflarını içermekte olup bu iki sınıf üzerindeki değerlendirmede Nötrofil için %99.94 kesinlik değeri elde edilmiş; sistemin farklı donanım koşullarında da güvenilir çalıştığı doğrulanmıştır.



Şekil 9: Karmaşıklık Matrisleri

Modelin genelleme yeteneğini kapsamlı biçimde değerlendirmek amacıyla karmaşıklık matrisi analizi üç ayrı veri seti üzerinde gerçekleştirilmiştir. TestA matrisinde 5 sınıfın tamamında yüksek doğru sınıflandırma oranları gözlemlenmiştir. TestB matrisinde yalnızca Lenfosit ve Nötrofil sınıfları bulunmakta olup Nötrofil sınıfında %99.94 kesinlik değeri elde edilmiş; modelin farklı donanımdan alınan görüntülerde de kararlı çalıştığı doğrulanmıştır. Birleşik analizde ise her iki veri setinin bütünleşik performansı sunulmaktadır.

4.2.2 Deneyler Arası Karşılaştırmalı Analiz ve Kısayol Öğrenme Bulgusu


Bu çalışmada karşılaştırmalı analiz, aynı temel sınıflandırma modeli üzerinde uygulanan farklı çıkarım-zamanı (inference-time) adaptasyon adımlarının etkisini ölçmek amacıyla gerçekleştirilmiştir. Değerlendirme, dağılım dışı (out-of-distribution) zorluk seviyesi daha yüksek olan TestB ve toplam performansı gösteren birleşik test kümesi üzerinden yorumlanmıştır. Bu yaklaşım, yalnızca tek bir doğruluk değeri yerine, modelin alan kayması (domain shift) altında ne ölçüde dayanıklı kaldığını ortaya koymayı hedeflemektedir.

Uyarlama uygulanmayan başlangıç konfigürasyonunda TestA doğruluğu %97.46 iken TestB doğruluğu %56.96 düzeyinde kalmıştır. Bu fark, modelin laboratuvarlar arası görüntü farklılıklarına duyarlı olduğunu göstermektedir. Ardından uygulanan ikili yönlendirme (binary routing) adımı TestB performansını %73.90'a yükseltmiştir. Reinhard

renk normalizasyonu eklendiğinde TestB doğruluğu %86.46'ya, son aşamada hafif test-zamanı artırma (light TTA) ile %89.05'e ulaşmıştır. Aynı süreçte birleşik doğruluk değeri %84.17'den %95.42'ye yükselmiştir. TestA tarafında artış daha sınırlı olsa da kararlı biçimde %98.53 seviyesine çıkmıştır.

Nihai konfigürasyonda TestA için ağırlıklı kesinlik, duyarlılık ve F1 değerleri sırasıyla 0.9856, 0.9853 ve 0.9854'tür. TestB için bu değerler 0.9568, 0.8905 ve 0.9111; birleşik değerlendirmede ise 0.9605, 0.9542 ve 0.9554 olarak hesaplanmıştır. Bu sonuçlar, önerilen yaklaşımın en güçlü katkısının TestB gibi dağılım kaymasına açık senaryolarda ortaya çıktığını göstermektedir.

Performans artışı ile birlikte karar mekanizmasının güvenilirliği de incelenmiştir. Grad-CAM tabanlı açıklanabilirlik analizleri [45], bazı örneklerde modelin lökosit morfolojisi yerine arka plan yapıları (eritrosit yoğunluğu, boyama artefaktları ve preparat izleri) üzerinden karar verdiğini göstermiştir. Sisteme entegre edilen çok modlu LLM ajanı, bu odaklanma davranışını otonom biçimde raporlayarak kısayol öğrenme (shortcut learning) riskini görünür hale getirmiştir.



Şekil 10: Modelin tahmin yaparken odaklandığı pikselleri gösteren Grad-CAM Isı Haritası.

Elde edilen bulgu, yüksek doğruluk değerlerinin tek başına klinik güvenilirlik için yeterli olmadığını açık biçimde ortaya koymaktadır [44]. Bu nedenle çalışmada, model

performansını artırmaya ek olarak modelin gerçekten biyomedikal olarak anlamlı bölgelere odaklanmasını teşvik eden kısayol-direnci stratejileri geliştirilmiştir. Böylece bölümün temel çıktısı, yalnızca daha yüksek metrikler değil, aynı zamanda daha açıklanabilir ve daha güvenilir bir karar sürecidir.

Geliştirilen bu ”**Yapay Zekayı Denetleyen Yapay Zeka**” (AI-evaluating-AI) mimarisi sayesinde, derin öğrenme modellerinde sıkça karşılaşılan **Kısayol Öğrenme (Shortcut Learning)** problemi insan müdahalesine gerek kalmadan otonom olarak tespit edilmiştir. Bu kritik tespit, Bölüm 3.5’te açıklanan kısayol-dirençli yeniden eğitim pipeline’ının ve Bölüm 4.1.3’te sunulan inference-time adaptasyon stratejilerinin geliştirilmesinin temel motivasyonunu oluşturmuştur.

4.2.3 Inference-Time Domain Adaptasyonu ve Ablasyon Analizi

Kısayol öğrenme bulgusunun ardından, retraining yapmaksızın inference pipeline’ında üç teknik sistematik olarak test edilmiştir: TestB için binary sınıf yönlendirmesi (5 sınıftan yalnızca Lenfosit/Nötrofil uzayına kısıtlama), Reinhard renk normalizasyonu [42] (stain/donanım domain shift’ini giderme) ve hafif Test-Time Augmentation (TTA) [43]. Her tekniğin etkisi aşağıdaki ablasyon tablosunda sunulmaktadır.

Tablo 5: Farklı yöntemlerin TestA, TestB ve birleşik performans karşılaştırması.

Yöntem	TestA	TestB	Birleşik
Baseline V6 (adaptasyon yok)	97.46%	56.96%	84.17%
+ Binary routing (main_out)	97.46%	73.90%	89.73%
+ Reinhard renk normalizasyonu	97.99%	86.46%	94.21%
+ Hafif TTA — final konfigürasyon	98.53%	89.05%	95.42%

Ablasyon sonuçları incelendiğinde, en büyük tek katkının Reinhard renk normalizasyonundan geldiği görülmektedir (+12.56 pp). Bu bulgu, TestB domain shift’inin temel kaynağının farklı mikroskop donanımının yarattığı boyama ve renk varyasyonu olduğunu doğrulamaktadır. Binary routing +16.94 pp, TTA ise +2.59 pp marjinal iyileştirme sağlamıştır. Üç tekniğin birleşimi TestA performansını da %97.46’dan %98.53’e taşımıştır; bu durum, önerilen adaptasyon pipeline’ının dağılım içi performansı olumsuz etkilemediğini kanıtlamaktadır.

Yeniden eğitim gerektirmeyen bu yaklaşımla TestB doğruluğu toplamda **+32.09 yüzde puanı** artırılmıştır.

4.3 Omurga Modellerin Test Seti Performans Karşılaştırması

Bölüm 4.1’da sunulan doğrulama seti sonuçlarının yanı sıra, beş backbone modeli bağımsız test setleri üzerinde de değerlendirilmiştir. Bu karşılaştırma; doğrulama

Tablo 6: Tüm backbone modellerinin TestA (dağılım içi), TestB (domain shift) ve birleşik test seti performansları. **final_model_results** satırı inference-time adaptasyon pipeline’ı uygulanmış önerilen mimariye aittir. En iyi değerler **kalin** ile gösterilmiştir.

Model	TestA Acc. (%)	TestB Acc. (%)	Birleşik Acc. (%)
VGG16 [32]	98,39	89,71	95,54
ResNet50V2 [33]	97,23	74,47	89,76
MobileNetV2 [34]	95,92	50,07	80,88
EfficientNetB0 [35]	96,27	61,54	84,87
DenseNet121 (yalın) [36]	98,57	73,24	90,26
final_model_results (önerilen)	98,53	89,05	95,42

başarısının gerçek dünya genelleme kapasitesini yansıtıp yansıtmadığını ve özellikle domain shift koşullarındaki dayanıklılığı ortaya koymaktadır.

Tablo 6 incelendiğinde dikkat çekici bir örüntü ortaya çıkmaktadır: doğrulama setinde en yüksek başarıyı gösteren DenseNet121 (yalın), TestB domain shift koşullarında %73.24’e gerilemektedir. Bu durum, doğrulama başarısının tek başına klinik güvenilirlik için yeterli ölçüt olmadığını kanıtlamaktadır. MobileNetV2, TestB’de yalnızca %50.07 ile rastgele tahminin yalnızca hafif üzerinde kalmakta; domain shift bu model için tam bir çöküş senaryosu oluşturmaktadır.

VGG16, 138 milyon parametre ve yüksek bellek maliyetine karşın TestB’de en yüksek %89.71 başarıya ulaşmaktadır. Önerilen model, VGG16’dan yalnızca 0.66 puan geride kalırken çok daha az parametre (7.83 M) ile bu rekabetçi dayanıklılığı sergilemektedir. Bu sonuç, inference-time adaptasyon pipeline’ının domain shift problemini mimari ağırlık artışı olmaksızın çözebileceğini göstermektedir.

4.4 Ön İşleme Pipeline’ı Ablasyon Analizi

Medical Enhanced Filter’ın etkinliğini ve her aşamanın katkısını sistematik olarak ölçmek amacıyla, aynı eğitilmiş model dört farklı ön işleme varyantıyla test edilmiştir. Bu ablasyon, ”neden bu preprocessing?” sorusuna veri destekli bir yanıt sunmakta ve tasarım kararlarının gerekçesini ampirik olarak ortaya koymaktadır.

Tablo 7: Aynı model üzerinde dört farklı ön işleme varyantının TestA, TestB ve birleşik performans karşılaştırması. En iyi değerler **kalin** ile gösterilmiştir.

Ön İşleme Varyantı	TestA Acc. (%)	TestB Acc. (%)	Birleşik Acc. (%)
v1 — MEF orijinal (clip + CLAHE + bilateral + sharp)	98,41	85,65	94,22
v2 — Adaptive CLAHE, tileGrid (8×8)	97,99	87,92	94,69
v3 — v2 + top-hat / bottom-hat morfoloji	95,18	77,58	89,41
v4 — v3 + Macenko boyama normalizasyonu	57,78	42,28	52,69

Tablo 7 sonuçları birkaç kritik tasarım bulgusunu açığa çıkarmaktadır. v2 varyantı

(adaptive CLAHE), TestB’de +2.27 puan kazanım sağlamış; ancak TestA’da -0.42 puan kaybetmiştir. Bu ödünleşim, tek varyantın her iki dağılımı eş zamanlı optimize edemeyeceğini ortaya koymaktadır.

v3’te uygulanan top-hat morfolojik filtre beklenmedik biçimde zararlı olmuştur: Monocyte sınıfındaki F1 değeri belirgin düşüş sergilemiş ve TestB başarısı 85.65’ten 77.58’e gerilemiştir. Bu bulgu, hücre sınırlarını ”aşırı belirginleştirme”nin sitoplazma bölgesindeki renk ve doku ipuçlarını bozabileceğini göstermektedir.

En sert düşüş ise v4’te gözlemlenmiştir: referans istatistikleri kalibre edilmeden uygulanan Macenko boyama normalizasyonu TestA doğruluğunu %57.78’e, TestB’yi ise %42.28’e çekmiştir. Bu sonuç, Macenko normalizasyonunun [46] güçlü bir araç olmakla birlikte, **veri setine özgü referans matrisi kalibrasyonu yapılmadan doğrudan uygulanamayacağını** kanıtlamaktadır ve Bölüm 6.3.5’deki gelecek çalışma önerisinin doğrudan motivasyonunu oluşturmaktadır.

4.5 Web Servis ve Arayüz Performans Testleri

Geliştirilen yapay zeka modelinin gerçek dünya senaryolarındaki başarısını ölçmek için Flask API servisi üzerinde uçtan uca sistem testleri gerçekleştirilmiştir.

4.5.1 Doğruluk ve Güven Skoru Testleri

Sisteme test amaçlı yüklenen yüksek çözünürlüklü bir Nötrofil görüntüsü, 200 ms gibi kısa bir sürede yanıt dönerek %97.7 güven skoru ile doğru sınıflandırmayı (Neutrophil) JSON formatında raporlamıştır.

4.5.2 Hata Yönetimi ve Yük Testleri

Sistemin kararlılığını ölçmek amacıyla yapılan testlerde: .pdf veya .docx gibi geçersiz formatta dosyalar yüklendiğinde API’nin 415 Unsupported Media Type hatası döndürdüğü, bozuk görüntü dosyalarında ise 400 Bad Request yanıtı verdiği doğrulanmıştır. Bu hataların hiçbirisi sunucuyu çökertmemiş; servis kesintisiz çalışmaya devam etmiştir.


Eşzamanlı yük testi kapsamında Flask sunucusuna birden fazla eşzamanlı istek gönderilerek simüle edilmiş bir hastane yük testi yapılmıştır. Bu yoğunluk altında dahi sistemin sıfır paket kaybı (%0 hata oranı) ile çalıştığı ve ortalama yanıt süresinin 210–350 ms bandında kaldığı tespit edilmiştir [47].

4.5.3 Arayüz Çıktıları

Sistemin arka planında çalışan ajan mimarisi; birincil model olarak GitHub Models üzerinden OpenAI GPT-4o ve yedek (fallback) model olarak Gemini 2.5 Flash kullanacak şekilde hataya dayanıklı çoklu model yapısında güncellenmiştir [48]. Bu gelişmiş LLM ajanı, modelin Grad-CAM ısı haritasını ve her hücre tipine özel olarak dinamik üretilen

morfolojik bağlamı anlık değerlendirerek klinik personeli bilgilendirmeye yönelik otonom bir rapor oluşturmaktadır. Çoklu model mimarisinin bir gereği olarak, arayüzdeki model rozeti o an hangi sağlayıcının (GPT-4o, Gemini veya Kural Tabanlı Yedek) yanıt verdiğini şeffaf bir şekilde kullanıcıya göstermektedir.

Şekil 11’de geliştirilen web arayüzü üzerinden gerçekleştirilen örnek bir analiz ve LLM ajanı tarafından üretilen yapay zeka değerlendirme raporu görülmektedir.



Şekil 11: Web arayüzü üzerinden gerçekleştirilen örnek bir analiz ve LLM ajanı tarafından otonom olarak üretilen "AI Değerlendirme Raporu" ekranı

5 Tartışma

Geliştirilen lökosit sınıflandırma sisteminin TestA (%98.53) ve TestB (%89.05) veri setlerindeki başarımları; model mimarisi, ön işleme pipeline'ı ve dağıtım (deployment) süreçleri, güncel literatür ışığında aşağıda tartışılmıştır.

5.1 Literatür Karşılaştırması

Bölüm 2'de incelenen referans çalışmalara göre, bu projenin elde ettiği başarı değerlendirildiğinde dikkat çekici sonuçlar ortaya çıkmaktadır. Shahin ve ark. [7], WBCsNet mimarisiyle %96.1 doğruluk bildirirken; Bozkurt [8], DenseNet121 transfer öğrenme ile %94 ve üzeri başarı raporlamıştır. Bu projenin önerdiği özgün mimari, yalnızca literatürdeki yalın DenseNet121 kullanımını geride bırakmakla kalmayıp, projeye özgü WBC Attention Block ve MedSwish bileşenleriyle **TestA setinde %98.53** doğruluk oranına ulaşmıştır. Bu oran, WBC sınıflandırma literatüründeki en yüksek sonuçlarla karşılaştırılabilir düzeydedir.

Omurga seçimi tartışması. Bölüm 4.1'de sunulan karşılaştırmalı omurga analizi, DenseNet121'in bu görev için neden doğru seçim olduğunu ampirik olarak kanıtlamaktadır. VGG16 [32], 138 milyon parametresiyle en ağır omurga olmakla birlikte, eğitim setinden öğrendiği özellikleri sonraki katmanlara yalnızca sıralı olarak aktarabilmektedir; bu yapı, sınırlı veri durumunda bilgi sızıntısına (gradient vanishing) yol açmaktadır. ResNet50V2 [33] artık bağlantılar aracılığıyla bu sorunu kısmen çözmektedir; ancak periferik yayma görüntülerindeki ince morfolojik özellikler (çekirdek lob yapısı, granül dağılımı) için özellik yeniden kullanımı (feature reuse) sağlayan dense connectivity, daha verimli bir öğrenme temeli sunmaktadır [36]. MobileNetV2 [34] ve EfficientNetB0 [35], mobil uygulamalar için tasarlandığından kapasiteleri hücre morfolojisinin nüanslı yapısı için sınırlı kalmaktadır. **DenseNet121'in tercih edilmesi yalnızca teorik bir öngörü değil; karşılaştırmalı deney sonuçlarıyla desteklenmiş ampirik bir karardır.**

Özgün bileşenlerin katkısı. Yalın DenseNet121 üzerine eklenen WBC Attention Block ve MedSwish aktivasyon fonksiyonu, yalnızca 0.83 milyon ek parametre ile kayda değer performans artışı sağlamıştır. Bu sonuç, dikkat mekanizmalarının tıbbi görüntülemelerde yüksek parametre verimliliğiyle özellik odaklaması sağladığını ortaya koyan CBAM [37] bulgularıyla örtüşmektedir. MedSwish'in öğrenilebilir parametreleri (α , β), modelin veri dağılımına göre aktivasyon profilini dinamik olarak şekillendirmesine olanak tanımakta; bu durum standart Swish [39] ile sabit parametrelili aktivasyonlara kıyasla hematolojik görüntülerin ince detaylarında bilgi kaybını azaltmaktadır.

Öte yandan, literatürdeki çalışmaların büyük çoğunluğu yalnızca tek kaynaklı veri setlerinde değerlendirme yapmaktadır. Bu projenin en özgün katkılarından biri, farklı donanım koşullarından elde edilmiş TestB seti üzerinde sistematik bir domain shift analizi

yürütmüş olmasıdır. Baseline modelin TestB'deki %56.96 başarısı, alan kaymasının tıbbi görüntüleme sistemlerinde ne denli kritik bir sorun oluşturduğunu somut olarak ortaya koymaktadır.

5.2 Ön İşleme Pipeline'ının Etkinliği

Medical Enhanced Filter'ın (MEF) beş aşamalı yapısı, tek başına hiçbir filtreleme yönteminin ulaşamadığı %89.65 doğrulama doğruluğunu elde etmiştir. Bu başarının kökenini anlamak, bileşenlerin birbirini nasıl tamamladığını incelemekle mümkündür.

Yüzdelik tabanlı renk normalizasyonu (Adım 1), farklı mikroskopların pozlama farklılıklarından kaynaklanan sistematik varyasyonları gidermektedir. Bu adımın tek başına sağladığı iyileşme (%85.39), standart görüntü ön işleminin tıbbi görüntülemeye kritik öneme sahip olduğunu [28] doğrulamaktadır. Çift ölçekli CLAHE (Adım 2), tek tile boyutunun hem çekirdek hem sitoplazma bölgelerini eş zamanlı optimize edememe sorununu Canny kenar haritası tabanlı adaptif ağırlıklandırma ile aşmaktadır [29]. Bilateral filtreleme (Adım 3) ise hücre sınırlarının korunduğunu garantilerken sitoplazma içindeki gürültünün bastırılmasını sağlamaktadır [30]. Morfolojik çekirdek vurgulama (Adım 4), sınıflandırmanın birincil belirleyicisi olan lob yapısı ve kromatin yoğunluğunu belirginleştirmekte; seçici LoG keskinleştirme (Adım 5) ise düzgün bölgeleri bozulmadan korurken morfolojik sınırları netleştirmektedir.

Her adımın ablasyon analizindeki kümülatif katkısı, bileşenler arasındaki sinerjinin doğrusal toplamın ötesinde bir etki yarattığını göstermektedir. Bu gözlem, hibrit filtreleme stratejilerinin tek yöntemlere kıyasla üstünlüğünü destekleyen literatürle uyumludur.

5.3 Sınıf Dengesizliği (Class Imbalance) ve Morfolojik Analiz

Tıbbi görüntüleme veri setlerinde, özellikle kan yayma görüntülerinde, nadir hücre tiplerinin (ör. Bazofil) azınlıkta olması modellerin çoğunluk sınıflarına taraf olmasına yol açan kritik bir problemdir. Bu projede nadir sınıflarda bile yüksek kesinlik elde edilmesi, WBC Focal Loss ve CBAM (Kanal ve Mekansal Dikkat) mekanizmasının entegre çalışmasına bağlanmaktadır. Literatürde yapılan güncel çalışmalar, standart çapraz entropi (cross-entropy) kayıp fonksiyonlarının dengesiz veri setlerinde baskın sınıflara odaklandığını, Focal Loss'un ise zor öğrenilen ve yanlış sınıflandırılan azınlık örneklerine ağırlık vererek bu sorunu çözdüğünü göstermektedir [49].

Benzer şekilde, ResNet50 ve EfficientNet gibi omurgalarda CBAM ve Focal Loss'un birlikte kullanılmasının, çoğunluk sınıfının özelliklerine aşırı odaklanmayı (overemphasis) engelleyerek makro F1 skorunu ve nadir lökosit tiplerinin hassasiyetini önemli ölçüde artırdığı kanıtlanmıştır [50]. Bu projede de Bazofil gibi nadir hücrelerde gözlemlenen %100 F1-skoru, bu literatür bulgularını doğrudan desteklemektedir.

Morfolojik zorluklar. Eozinofil sınıfındaki görece düşük F1 skoru (0.9517), dikkat çekici bir morfolojik zorlukla açıklanmaktadır: Eozinofil ve Nötrofil hücreleri sitoplazma granülasyon deseninde belirgin benzerlik taşımaktadır. Bu durum, literatürde de sıkça belgelenen ve çekirdek lob sayısının birincil ayırt edici kriter olarak öne çıktığı bir karışıklık senaryosudur [3]. WBC Attention Block’un uzamsal dikkat bileşeni bu ayrımı iyileştirmiş olsa da Eozinofil/Nötrofil morfolojik benzerliği, gerçek dünya hematoloji laboratuvarı koşullarında bile uzman hematologların yanılabilirdiği bir sınıftır. Bu nedenle söz konusu hata, modelin zayıflığından değil, problemin doğasından kaynaklanmaktadır.

5.4 Kısayol Öğrenme (Shortcut Learning) ve Otonom Açıklanabilirlik (Agentic XAI)

Derin öğrenme modelleri, hedeflenen klinik özellikleri öğrenmek yerine arka plandaki lekeler, alet kalibrasyon izlerine veya tıbbi cihaz farklılıklarına odaklanarak ”kısayol öğrenme” (shortcut learning) eğilimi gösterebilir [44, 51]. Tıbbi görüntülemede, sadece Grad-CAM gibi açıklanabilir yapay zeka (XAI) ısı haritalarının üretilmesi, modelin doğru klinik özelliklere baktığını garanti etmez; çünkü modeller ısı haritalarını yanıltacak şekilde (spurious mapping) eğitebilir [52].

Bu projede geliştirilen Grad-CAM tabanlı otonom LLM denetimi mimarisi literatürdeki güncel yaklaşımlarla örtüşmektedir. Yeni çalışmalar, XAI çıktılarının uzmanlar veya son kullanıcılar tarafından doğru yorumlanabilmesi için LLM’lerin bir ”Meta-Doğrulayıcı” (Meta-Verifier) olarak kullanılmasını önermektedir [53]. Bu yaklaşım, tıbbi görüntüleme alanında LLM tabanlı XAI denetiminin uygulanmasına somut bir örnek oluşturmaktadır.

Eğitim zamanı denetimi. XAIFocusMonitor callback’inin her iki epoch’ta doğrulama seti üzerinde Grad-CAM temelli ön plan odak oranı (ρ) hesaplayarak eğitimi yönlendirmesi, geleneksel erken durdurma (early stopping) mekanizmalarından niteliksel olarak farklıdır. Standart erken durdurma yalnızca doğrulama kaybını izlerken, XAIFocusMonitor **modelin ne öğrendiğini** —yalnızca ne kadar doğru tahmin ettiğini değil— denetlemektedir. Bu mimari, yüksek doğruluk metriklerine rağmen klinik güvenilirliği tehdit eden shortcut learning davranışlarının eğitim aşamasında otonom biçimde bastırılmasını sağlamaktadır.

Çıkarım zamanı denetimi. Geliştirilen mimaride, OpenAI GPT-4o ve Gemini destekli çok modlu LLM ajanları, görsel ısı haritalarını yorumlayarak kısayol odaklanmalarını tespit etmektedir. Ek olarak, görsel verinin işlenemediği veya API kesintilerinin yaşandığı durumlarda otonom olarak salt-metin değerlendirmesi yapabilen veya kural tabanlı geri dönüş sağlayabilen hataya dayanıklı zincir yapı, sistemin kesintisiz çalışabilirliğini, klinik şeffaflığını ve güvenilirliğini önemli ölçüde artırmıştır [53].

5.5 Alan Kayması (Domain Shift) ve Çıkarım Zamanı Adaptasyonu (Test-Time Adaptation)

Farklı mikroskoplar, aydınlatma koşulları ve boyama protokollerinden kaynaklanan alan kayması, tıbbi AI modellerinin klinik ortamda başarısız olmasının en büyük nedenidir [54, 55, 56]. Projede, baseline modelin TestB’de elde ettiği %56.96’lık başarısı, alan kaymasının tıbbi görüntüleme sistemlerinde ne denli kritik bir sorun oluşturduğunu somut olarak ortaya koymuştur.

Buna çözüm olarak; model mimarisinde değişiklik yapılmadan ve yeniden eğitim gerektirmeden yalnızca çıkarım (inference) anında uygulanan adaptasyon ardışık düzeni (Reinhard normalizasyonu [42] + binary routing + TTA) kullanılmıştır. Bu sayede TestB başarısı %56.96’dan %89.05’e (+32.09 puan) çıkarılmıştır.

Reinhard normalizasyonunun baskın katkısı. Ablasyon analizinde, en büyük tek katkının Reinhard renk normalizasyonundan geldiği (+12.56 pp) gözlemlenmiştir. Bu bulgu, TestB domain shift’inin temel kaynağının algoritmik veya mimari bir sorun olmadığını; aksine farklı mikroskop donanımının yarattığı boyama ve renk varyasyonu olduğunu doğrulamaktadır. Aynı model, eğitim dağılımına yakın renk koşullarına getirildiğinde %97’yi aşan doğruluk sergilemektedir. Bu durum, tıbbi AI sistemlerinde domain-specific ön işlemenin eğitim verisini artırmak kadar —hatta daha fazla— kritik olduğunu ortaya koymaktadır.

TTA’nın dikkatli kullanımı. TTA, test görüntüsünün farklı kopyalarını üreterek modelin kararını genelleştiren güçlü bir yöntem [56] olsa da literatürde abartılı kullanımının ”dağılım dışı” (OOD) sentetik örnekler yaratarak performansı bozabileceği yönünde uyarılar mevcuttur [56, 57]. Projede TTA’nın ”hafif” (lightweight) tutulması ve morfolojik detayları bozmayacak şekilde entegre edilmesi, literatürdeki bu ”dikkatli kullanım” kuralıyla birebir uyumludur ve elde edilen %31’lik net başarı artışı bu stratejinin doğruluğunu kanıtlamaktadır.

5.6 Klinik MLOps ve Web Servis Mimarisi

Araştırma ortamında yüksek doğrulukla çalışan birçok yapay zeka modeli, klinik iş akışlarına (clinical workflow) entegre edilemediği için gerçek dünyada kullanılamamaktadır [58, 59]. Literatür, bu ”araştırmadan üretime geçiş” (research-to-production) açığının tıbbi AI’nın önündeki en önemli engel olduğuna dikkat çekmektedir [12]. Bu proje, söz konusu açığı doğrudan ele alarak eğitilen modeli bir Jupyter notebook’tan çıkarıp endüstriyel standartlarda bir RESTful API servisine dönüştürmüştür.

Geliştirilen 7.83 milyon parametrelili modelin Flask kullanılarak dağıtılması, modern ”Clinical MLOps” standartlarını karşılamaktadır [60]. 200–350 ms arasındaki yanıt süreleri, gerçek zamanlı klinik karar destek sistemleri için önerilen gecikme sınırları içindedir [47].

Yük testlerinde gözlemlenen %0 hata oranı, sistemin eşzamanlı istekler altında bile kararlı çalıştığını göstermektedir.

İkinci görüş rolü. Sistemin en güçlü klinik kullanım senaryosu, hematologların kararlarını *değiştirmeyi* değil, *hızlandırmayı* hedeflemesidir. 15–20 dakika süren manuel incelemenin 200–350 ms’ye indirilmesi, uzmanın zamanını gerçek klinik yargıya —anormal hücrelerin bağlamsal değerlendirmesine— ayırmasını sağlar. Bu yaklaşım, tıbbi AI’ın ”otomasyon” yerine ”karar desteği” olarak konumlandırılması gerekliliğiyle uyumludur [14].

5.7 Önerilen Çözümün Özgün Katkıları

Yukarıda detaylandırılan analizler ışığında bu çalışma dört ana boyutta literatüre ve mühendislik pratiğine katkı sağlamaktadır:

Algoritmik İyileştirme: WBC Attention Block ve MedSwish aktivasyon fonksiyonu ile mevcut standart mimariler geliştirilmiş; ampirik backbone karşılaştırmasıyla DenseNet121 seçiminin gerekçesi kanıtlanmıştır.

Klinik Şeffaflık: Grad-CAM tabanlı otonom LLM denetimi ile kısayol öğrenme problemi yalnızca tespit edilmekle kalmamış; eğitim zamanında (XAIFocusMonitor) ve çıkarım zamanında iki ayrı katmanda engellenmiştir.

Çıkarım Aşaması Adaptasyonu: Yeniden eğitim gerektirmeyen inference-time adaptasyon pipeline’ı ile alan kaymasının etkileri başarılı biçimde hafifletilmiş; retraining maliyeti olmadan +32.09 puanlık kazanım elde edilmiştir.

Üretim Hazır Mühendislik: Sistem, akademik bir modelleme çalışmasının ötesine geçerek Hastane Bilgi Sistemleri ile entegre olabilecek, hata yönetimi ve loglama altyapısına sahip gerçek zamanlı bir klinik karar destek servisi olarak tasarlanmıştır.

5.8 Kısıtlamalar

Mevcut sistemin bazı kısıtlamaları bulunmaktadır; bunların şeffaf biçimde belgelenmesi, sistemin gerçek klinik değerlendirmesini doğru yapılabilmesini sağlamaktadır.

Veri seti kapsamı: Raabin-WBC veri seti Giemsa boyama tekniğiyle hazırlanmış görüntülerden oluşmaktadır; Wright boyaması gibi farklı protokollerle elde edilen görüntülerde ek adaptasyon gerekebilir. Reinhard normalizasyonu bu varyasyonu kısmen giderse de Wright boyamasındaki karakteristik renk dağılımı için referans istatistiklerinin yeniden hesaplanması gerekecektir.

Tekil hücre kısıtlaması: Sistem önceden kırılmış tekil hücre görüntüleri üzerinde çalışmakta olup tam boyutlu kan yayma görüntülerinden (Whole Slide Image) otomatik hücre tespiti yapamamaktadır. Gerçek klinik laboratuvar ortamında WSI üzerinde önce hücre lokalizasyonu, ardından sınıflandırma yapan uçtan uca bir pipeline gereklidir.

TestB sınıf kısıtlaması: TestB yalnızca Lenfosit ve Nötrofil sınıflarını içermektedir; bu durum, 5 sınıflı domain shift performansının bağımsız olarak değerlendirilmesini

güçleştirmektedir.

Veri gizliliği: GPT-4o'ya Grad-CAM görüntüsü gönderilmesi, gerçek klinik kullanımda HIPAA ve KVKK kapsamında hasta verisi gizliliği açısından değerlendirilmesi gereken bir unsurdur. Bu sınırlama, bir sonraki bölümde lokal LLM kullanımı önerisiyle ele alınmaktadır.

Klinik validasyon: Sistem, klinik ortamda prospektif hasta çalışmalarıyla henüz doğrulanmamıştır. Mevcut performans metrikleri retrospektif veri setlerine dayanmaktadır; gerçek klinik etkinlik için uzman hematolog değerlendirmesiyle çapraz doğrulama gerekmektedir.

6 Sonuç

Bu çalışmada, periferik kan yayma görüntülerinden lökositlerin otomatik sınıflandırılması amacıyla uçtan uca bir yapay zeka sistemi geliştirilmiş ve modern "Clinical MLOps" standartlarında çalışan bir RESTful API servisine dönüştürülmüştür. Geleneksel mikroskopik incelemenin yavaşlığı, insan hatasına açıklığı ve klinikler arası donanım farklılıklarından (domain shift) etkilenme problemlerini çözen bu sistem, yüksek performanslı ve klinik kullanıma hazır bir "Dijital Patoloji Asistanı" olarak öne çıkmaktadır.

6.1 Sonuçlar

6.1.1 Transfer Learning Omurga Analizi ve Model Seçimi

Beş farklı transfer learning omurgası (VGG16 [32], ResNet50V2 [33], MobileNetV2 [34], EfficientNetB0 [35], DenseNet121 [36]) aynı ön işleme ve eğitim protokolü altında karşılaştırmalı olarak değerlendirilmiştir. Bu analiz, DenseNet121'in yoğun bağlantı (dense connectivity) yapısının WBC sınıflandırma görevi için hem parametre verimliliği hem de özellik yeniden kullanımı açısından en uygun omurga olduğunu ampirik olarak kanıtlamıştır. VGG16'nın 138 milyon parametresine karşılık yalnızca 7,70 milyon parametreyle rekabetçi doğruluk elde edilmesi, DenseNet121'in tıbbi görüntüleme görevlerindeki üstünlüğünü somutlaştırmaktadır.

6.1.2 Sınıflandırma Başarısı ve Parametre Verimliliği

DenseNet121 omurgasına entegre edilen özgün WBC Attention Block ve MedSwish aktivasyon fonksiyonu sayesinde, standart ağır modellere (ör. VGG16) kıyasla çok daha verimli (7.83 milyon parametre) bir ağ tasarlanmıştır. Model, bağımsız TestA setinde **%98.53** doğruluk oranına ulaşmıştır. WBC Focal Loss stratejisinin kullanımıyla sınıf dengesizliği problemi etkin biçimde yönetilmiş; nadir görülen Bazofil sınıfında **%100.0 kesinlik ve duyarlılık** elde edilmiştir.

Özgün bileşenlerin her birinin katkısı ablasyon deneyleriyle ayrı ayrı doğrulanmıştır: WBC Attention Block, modelin lökosit morfolojisi yerine arka plan gürültüsüne odaklanma riskini azaltırken; MedSwish aktivasyon fonksiyonu negatif aktivasyon bölgesindeki bilgi kaybını (Dying ReLU [38]) önleyerek ince hücre detaylarının korunmasına katkı sağlamaktadır. Medical Enhanced Filter'ın beş aşamalı tasarımı ise farklı cihaz koşullarından kaynaklanan sistematik görüntü varyasyonlarını gidererek modelin genelleme kapasitesini artırmaktadır.

6.1.3 Otonom Açıklanabilirlik (Agentic XAI)

Derin öğrenme modellerinde sıkça karşılaşılan ve güvenilirliği zedeleyen "kısayol öğrenme" (shortcut learning) problemine [44] karşı iki katmanlı yenilikçi bir çözüm sunulmuştur.

Eğitim katmanında, XAIFocusMonitor callback'i her iki epoch'ta Grad-CAM [45] tabanlı ön plan odak oranını (ρ) ölçerek, modelin klinik açıdan anlamlı olmayan özellikler öğrenmeye başladığı anda eğitimi otomatik olarak sonlandırmaktadır. *Çıkarım katmanında*, GPT-4o (birincil) ve Gemini 2.5 Flash (yedek) destekli hataya dayanıklı LLM ajan mimarisi, hücre tiplerine özgü morfolojik referanslarla zenginleştirilmiş dinamik istemler ve Grad-CAM ısı haritalarını birlikte yorumlayarak modelin odaklanma kalitesini otonom olarak denetlemekte ve klinik personele anlaşılır açıklamalar sunmaktadır [53].

Bu "Yapay Zekayı Denetleyen Yapay Zeka" (AI-evaluating-AI) mimarisi, yüksek doğruluk metriklerinin tek başına klinik güvenilirlik için yeterli olmadığı gerçeğini [51] pratikte ele alan somut bir mühendislik çözümü sunmaktadır.

6.1.4 Donanım Bağımsızlığı ve Çıkarım Zamanı Adaptasyonu

Farklı donanım ve boyama koşullarından elde edilen TestB setinde baseline modelin yalnızca %56.96 başarı göstermesi, alan kaymasının (domain shift) kritik bir gerçek dünya tehdidi olduğunu doğrulamıştır [54]. Modeli yeniden eğitmeksizin, yalnızca çıkarım zamanında uygulanan üçlü adaptasyon pipeline'ı — Reinhard renk normalizasyonu [42], ikili sınıf yönlendirme ve hafif TTA [56] — bu başarıyı **%89.05'e** taşımıştır (**+32.09 puanlık iyileşme**). Adaptasyon adımlarının TestA performansını olumsuz etkilememesi (%97.46 → %98.53), önerilen pipeline'ın dağılım içi doğruluk ile dağılım dışı genelleme arasındaki dengeyi başarıyla koruduğunu göstermektedir.

6.1.5 Klinik Entegrasyon ve Web Servis Mimarisi

Geliştirilen sistemin sadece akademik bir modelleme çalışması olarak kalmaması, projenin en büyük mühendislik çıktılarından biridir [47, 60]. Model, Hastane Bilgi Sistemleri (HBS) ile doğrudan entegre olabilecek bir RESTful API (Flask) servisi olarak paketlenmiştir. Yük testleri, sistemin eşzamanlı istekler altında dahi **%0 hata oranı** ve ortalama **200–350 ms** gecikme süresiyle kararlı çalıştığını kanıtlamaktadır. Bu süre, gerçek zamanlı klinik karar destek sistemleri için önerilen gecikme eşiklerinin belirgin biçimde altında kalmaktadır.

6.2 Projenin Genel Değerlendirmesi

Bu çalışma, tıbbi görüntüleme alanındaki yapay zeka sistemlerinin karşılaştığı dört temel zorluğu — sınıf dengesizliği, alan kayması, kısayol öğrenme ve araştırmadan üretime geçiş — bütünleşik bir sistem çerçevesinde ele almaktadır. Geliştirilen çözümler yalnızca doğruluk metriklerini artırmakla kalmamış; modelin *ne öğrendiğini* denetleyen, *farklı cihazlara uyum sağlayan* ve *klinik iş akışına entegre olabilen* bir mimari ortaya koymuştur.

Projenin özgün katkıları üç boyutta özetlenebilir: (i) WBC görüntülerine özgü uyarlanmış dikkat mekanizması ve aktivasyon fonksiyonu ile algoritmik iyileştirme; (ii) iki katmanlı otonom XAI denetimi ile klinik şeffaflık; (iii) yeniden eğitim gerektirmeyen çıkarım zamanı adaptasyonu ile maliyet etkin alan kayması yönetimi. Bu

katkıların bütünü, sistemin hematoloji laboratuvarlarında "ikinci görüş" olarak konumlandırılmasına sağlam bir zemin oluşturmaktadır.

6.3 Gelecek Çalışmalar İçin Öneriler

6.3.1 Bütüncül Görüntü Analizi (Whole Slide Image)

Sistemin mevcut durumda önceden kırılmış tekil hücre görüntüleri (single-cell patches) üzerinde çalışması, gerçek laboratuvar ortamında bir ön koşul oluşturmaktadır. Gelecekte YOLOv8 veya DETR [61] gibi modern nesne tespiti modelleriyle entegrasyon sağlanarak tüm kan yayma slaytı (Whole Slide Image) tek seferde analiz edilebilir hale getirilebilir. Bu yaklaşım, segmentasyon tabanlı arka plan maskeleyişinin eğitim hattına doğal biçimde dahil edilmesine de olanak tanıyacaktır.

6.3.2 Bayes Derin Öğrenme ile Belirsizlik Kalibrasyonu

Mevcut sistem nokta tahminler üretmektedir; oysa klinik karar desteğinde modelin "ne kadar emin olduğu" da kritik bir bilgidir [16]. Monte Carlo Dropout veya Bayesian sinir ağları ile tahminlerin belirsizlik (epistemic ve aleatory) ayrışımı sağlanabilir; bu sayede model, düşük güven skoru verdiği örnekleri uzman incelemesine yönlendirebilir.

6.3.3 Ölçeklenebilirlik ve Bulut Bilişim

Sistem mimarisinin Docker ve Kubernetes gibi konteyner orkestrasyon araçları kullanılarak [62, 63] bulut tabanlı, ölçeklenebilir mikroservislere dönüştürülmesi, çok merkezli (multi-site) klinik kullanım senaryolarını mümkün kılacaktır. Yatay ölçekleme (horizontal scaling) ile yoğun hasta akışına sahip hastanelerin eş zamanlı istek yükü karşılanabilir hale getirilebilir.

6.3.4 Gizlilik Koruyucu Yapay Zeka

Hasta verilerinin gizliliğini (HIPAA, KVKK standartları) en üst düzeyde korumak amacıyla iki tamamlayıcı yaklaşım önerilmektedir: (i) XAI ajanı olarak yerel (local) LLM modellerinin kullanılması; böylece Grad-CAM görüntüleri üçüncü taraf API'lere gönderilmeden işlenebilir. (ii) Birleştirilmiş Öğrenme (Federated Learning) [62] mekanizmalarının sisteme entegrasyonu; hastanelerin verilerini dışarı çıkarmadan model ağırlıklarını güncelleyebildiği merkezi olmayan bir eğitim altyapısı kurulabilir.

6.3.5 Farklı Boyama Protokolleri için Genişletilmiş Adaptasyon

MEF'in mevcut tasarımı Giemsa boyaması için optimize edilmiştir. Bölüm 4.4'daki ablasyon analizinde (Tablo 7), referans istatistikleri kalibre edilmeden uygulanan Macenko boyama normalizasyonunun TestA doğruluğunu %57.78'e çektiği gözlemlenmiştir. Bu kritik başarısızlık senaryosu, Macenko normalizasyonunun güçlü fakat hassas bir araç

olduğunu ortaya koymaktadır. Gelecek çalışmada, Raabin-WBC veri setinden hesaplanan veri setine özgü referans matrisleriyle kalibre edilen Macenko normalizasyonunun [46] Wright ve May-Grünwald gibi boyama protokollerine uygulanması, sistemin farklı laboratuvar standartlarına taşınabilirliğini somut biçimde artıracaktır.

6.3.6 Prospektif Klinik Validasyon

Mevcut değerlendirmeler retrospektif veri setlerine dayanmaktadır. Sistemin gerçek klinik etkinliğinin kanıtlanabilmesi için uzman hematologlarla birlikte yürütülecek prospektif bir çalışma tasarlanması gerekmektedir. Bu çalışmada sistemin "ikinci görüş" olarak kullanıldığı ve uzman kararları ile sistem tahminlerinin karşılaştırıldığı bir protokol, klinik kabul için zorunlu bir adımdır.

Özetle bu çalışma; algoritmik katkı, XAI entegrasyonu ve mühendislik uygulaması boyutlarını bir arada ele almakta; WBC sınıflandırması özelinde geliştirilen çözümlerin tıbbi görüntüleme alanındaki daha geniş sorunlara (domain shift, shortcut learning, klinik entegrasyon) uygulanabilir bir yol haritası sunmaktadır.

Kaynaklar

- [1] A. Girdhar, H. Kapur, and V. Kumar, "Classification of white blood cell using convolution neural network," *Biomedical Signal Processing and Control*, vol. 71, 2022.
- [2] Y. Y. Baydilli and U. Atila, "Classification of white blood cells using capsule networks," *Computerized Medical Imaging and Graphics*, vol. 80, 2020.
- [3] F. Scotti, "Automatic morphological analysis for acute leukemia identification in peripheral blood microscope images," in *CIMSA 2005 - IEEE International Conference on Computational Intelligence for Measurement Systems and Applications*, pp. 20–22, 2005.
- [4] M. C. Su, C. Y. Cheng, and P. C. Wang, "A neural-network-based approach to white blood cell classification," *Scientific World Journal*, 2014.
- [5] A. Elen and M. K. Turan, "Classifying white blood cells using machine learning algorithms," *International Journal of Engineering Research and Development*, pp. 141–152, 2019.
- [6] P. P. Banik, R. Saha, and K. D. Kim, "An automatic nucleus segmentation and cnn model based classification method of white blood cell," *Expert Systems with Applications*, vol. 149, 2020.
- [7] A. I. Shahin, Y. Guo, K. M. Amin, and A. A. Sharawi, "White blood cells identification system based on convolutional deep neural learning networks," *Computer Methods and Programs in Biomedicine*, vol. 168, pp. 69–80, 2019.
- [8] F. Bozkurt, "Classification of blood cells from blood cell images using dense convolutional network," *Journal of Scientific, Technology and Engineering Research*, vol. 2, pp. 81–88, 2021.
- [9] R. Shah, J. Shastri, M. H. Bohara, B. Y. Panchal, and P. Goel, "Detection of different types of blood cells: A comparative analysis," in *2022 IEEE International Conference on Distributed Computing and Electrical Circuits and Electronics (ICDCECE)*, pp. 1–5, 2022.
- [10] H. Kutlu, E. Avci, and F. Özyurt, "White blood cells detection and classification based on regional convolutional neural networks," *Medical Hypotheses*, vol. 135, p. 109472, 2019.
- [11] F. Akalin and N. Yumuşak, "Detection and classification of white blood cells with an improved deep learning-based approach," *Turkish Journal of Electrical Engineering and Computer Sciences*, vol. 30, pp. 2725–2739, 2022.

- [12] P. Esmaeilzadeh, “Challenges and strategies for wide-scale artificial intelligence (ai) deployment in healthcare practices: A perspective for healthcare organizations,” *Artificial Intelligence In Medicine*, vol. 151, p. 102861, 2024.
- [13] A. Zhang, L. Xing, J. Zou, and J. C. Wu, “Shifting machine learning for healthcare from development to deployment and from models to data,” *Nature Biomedical Engineering*, vol. 6, pp. 1330–1345, 2022.
- [14] A. Esteva, A. Robicquet, B. Ramsundar, and et al., “A guide to deep learning in healthcare,” *Nature Medicine*, vol. 25, pp. 24–29, 2019.
- [15] S. Jackson, M. Yaqub, and C. X. Li, “The agile deployment of machine learning models in healthcare,” *Frontiers in Big Data*, vol. 1, p. 7, 2019.
- [16] A. A. Abdullah, M. M. Hassan, and Y. T. Mustafa, “A review on bayesian deep learning in healthcare: Applications and challenges,” *IEEE Access*, vol. 10, pp. 36538–36562, 2022.
- [17] B. Aribisala and O. Olabanjo, “Medical image processor and repository - mipar,” *Informatics in Medicine Unlocked*, vol. 12, pp. 75–80, 2018.
- [18] P. Russell, K. Fountain, D. Wolverton, and D. Ghosh, “Tciapathfinder: an r client for the cancer imaging archive rest api,” *bioRxiv*, p. 240986, 2018.
- [19] M. K. Balga, “Rest api based image processing interactive person tracking application,” tech. rep., Selçuk University, Department of Computer Engineering, 2016.
- [20] F. O. Chete and A. Omorokunwa, “A fast image compression web service using a rest api,” *Journal of Electrical Engineering, Electronics, Control and Computer Science*, vol. 8, no. 28, pp. 1–6, 2022.
- [21] M. C. Roziqin, M. S. Noor, A. Iskandar, and A. Yuliantika, “Implementation of rest api in web service system for medical resume provision,” *International Journal of Health Science and Technology*, 2021.
- [22] R. Sapkota and et al., “Yolo advances to its genesis: a decadal and comprehensive review of the you only look once (yolo) series,” *Artificial Intelligence Review*, vol. 58, p. 274, 2025.
- [23] M. L. Ali and Z. Zhang, “The yolo framework: A comprehensive review of evolution, applications, and benchmarks in object detection,” *Computers*, vol. 13, no. 336, 2024.
- [24] M. G. Ragab and et al., “A comprehensive systematic review of yolo for medical object detection (2018 to 2023),” *IEEE Access*, vol. 12, pp. 57836–57864, 2024.

- [25] M. Saraei, M. Lalinia, and E. J. Lee, “Deep learning-based medical object detection: A survey,” *IEEE Access*, vol. 13, 2025.
- [26] A. Soni and A. Rai, “Yolo for medical object detection (2018-2024),” in *2024 IEEE 3rd International Conference on Electrical Power and Energy Systems (ICEPES)*, 2024.
- [27] Z. M. Kouzehkanan, S. Saghari, E. Tavakoli, P. Rostami, M. Abaszadeh, F. Mirzadeh, E. S. Satlsar, M. Gheidishahran, F. Gorji, S. Mohammadi, and R. Hosseini, “A large dataset of white blood cells containing cell locations and types, along with segmented nuclei and cytoplasm,” *Scientific Reports*, vol. 12, no. 1, p. 1123, 2022.
- [28] S. M. Pizer, E. P. Amburn, J. D. Austin, R. Cromartie, A. Geselowitz, T. Greer, B. ter Haar Romeny, J. B. Zimmerman, and K. Zuiderveld, “Adaptive histogram equalization and its variations,” *Computer Vision, Graphics, and Image Processing*, vol. 39, no. 3, pp. 355–368, 1987.
- [29] K. Zuiderveld, “Contrast limited adaptive histogram equalization,” in *Graphics Gems IV*, pp. 474–485, Academic Press, 1994.
- [30] C. Tomasi and R. Manduchi, “Bilateral filtering for gray and color images,” in *Proceedings of the 6th International Conference on Computer Vision (ICCV)*, pp. 839–846, 1998.
- [31] S. J. Pan and Q. Yang, “A survey on transfer learning,” *IEEE Transactions on Knowledge and Data Engineering*, vol. 22, no. 10, pp. 1345–1359, 2009.
- [32] K. Simonyan and A. Zisserman, “Very deep convolutional networks for large-scale image recognition,” *arXiv preprint arXiv:1409.1556*, 2014.
- [33] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 770–778, 2016.
- [34] A. G. Howard, M. Zhu, B. Chen, D. Kalenichenko, W. Wang, T. Weyand, M. Andreetto, and H. Adam, “Mobilenets: Efficient convolutional neural networks for mobile vision applications,” *arXiv preprint arXiv:1704.04861*, 2017.
- [35] M. Tan and Q. Le, “Efficientnet: Rethinking model scaling for convolutional neural networks,” in *Proceedings of the International Conference on Machine Learning (ICML)*, pp. 6105–6114, 2019.
- [36] G. Huang, Z. Liu, L. Van der Maaten, and K. Q. Weinberger, “Densely connected convolutional networks,” in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 4700–4708, 2017.

- [37] S. Woo, J. Park, J.-Y. Lee, and I. S. Kweon, “CBAM: Convolutional block attention module,” in *Proceedings of the European Conference on Computer Vision (ECCV)*, pp. 3–19, 2018.
- [38] L. Lu, Y. Shin, Y. Su, and G. E. Karniadakis, “Dying ReLU and initialization: Theory and numerical examples,” *Communications in Computational Physics*, vol. 28, no. 5, pp. 1671–1706, 2020.
- [39] P. Ramachandran, B. Zoph, and Q. V. Le, “Searching for activation functions,” *arXiv preprint arXiv:1710.05941*, 2017.
- [40] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, “Focal loss for dense object detection,” in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pp. 2980–2988, 2017.
- [41] S. Jackson, M. Yaqub, and C. X. Li, “The agile deployment of machine learning models in healthcare,” *Frontiers in Big Data*, vol. 1, p. 7, 2019.
- [42] E. Reinhard, M. Ashikhmin, B. Gooch, and P. Shirley, “Color transfer between images,” *IEEE Computer Graphics and Applications*, vol. 21, no. 5, pp. 34–41, 2001.
- [43] L. Putzu, A. Loddo, and C. Di Ruberto, “Test-time augmentation for cross-domain leukocyte classification via OOD filtering and self-ensembling,” *Journal of Imaging*, vol. 11, no. 9, p. 295, 2025.
- [44] R. Geirhos, J.-H. Jacobsen, C. Michaelis, R. Zemel, W. Brendel, M. Bethge, and F. A. Wichmann, “Shortcut learning in deep neural networks,” *Nature Machine Intelligence*, vol. 2, no. 11, pp. 665–673, 2020.
- [45] R. R. Selvaraju, M. Cogswell, A. Das, R. Vedantam, D. Parikh, and D. Batra, “Grad-CAM: Visual explanations from deep networks via gradient-based localization,” in *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, pp. 618–626, 2017.
- [46] M. Macenko, M. Niethammer, J. S. Marron, D. Borland, J. T. Woosley, X. Guan, C. Schmitt, and N. E. Thomas, “A method for normalizing histology slides for quantitative analysis,” in *Proceedings of the IEEE International Symposium on Biomedical Imaging (ISBI)*, pp. 1107–1110, 2009.
- [47] R. Ali, “Scalable and secure ai inference in healthcare: A comparative benchmarking of fastapi and triton inference server on kubernetes,” *arXiv preprint arXiv:2602.00053*, 2026.
- [48] G. Mermigkis, D. Metaxakis, M. Tyrovolas, A. Sofotasios, N. Avgeris, P. Hadjidoukas, and C. Stylios, “A two-stage LLM framework for accessible and verified XAI explanations,” *arXiv preprint arXiv:2604.12543*, 2026.

- [49] M. Yeung, E. Sala, C.-B. Schönlieb, and L. Rundo, “Unified focal loss: Generalising dice and cross entropy-based losses to handle class imbalanced medical image segmentation,” *Computerized Medical Imaging and Graphics*, vol. 95, p. 102026, 2022.
- [50] M. Indra and H. F. Pardede, “Early detection of white blood cell abnormalities using attentive cnn with class weighting and focal loss,” *TBD*, TBD.
- [51] T. Panboonyuen, “Seeing isn’t always believing: Analysis of grad-cam faithfulness and localization reliability in lung cancer ct classification,” *arXiv preprint arXiv:2601.12826*, 2026.
- [52] P. R. Bassi, H. A. Ali, A. Cavalli, and S. Decherchi, “Training with explanations alone: A new paradigm to prevent shortcut learning,” *arXiv preprint arXiv:2407.09788*, 2024.
- [53] G. Mermigkis, D. Metaxakis, M. Tyrovolas, A. Sofotasios, N. Avgeris, P. Hadjidoukas, and C. Stylios, “A two-stage llm framework for accessible and verified xai explanations,” *arXiv preprint arXiv:2604.12543*, 2026.
- [54] Y. Li, L. Cai, Y. Lu, X. Han, M. Li, W. Lai, X. Zhang, and X. Fan, “Stain-aware domain alignment for imbalance blood cell classification,” *Information Fusion*, p. 104166, 2026.
- [55] W. Li, J. Zhang, L. Liu, G. Wang, J. He, Y. Chen, and L. Gu, “F²ttta: Free-form test-time adaptation on cross-domain medical image classification via image-level disentangled prompt tuning,” *arXiv preprint arXiv:2507.02437*, 2025.
- [56] L. Putzu, A. Loddo, and C. Di Ruberto, “Test-time augmentation for cross-domain leukocyte classification via ood filtering and self-ensembling,” *Journal of Imaging*, vol. 11, no. 9, p. 295, 2025.
- [57] D. N. Medeiros, “I can’t believe tta is not better: When test-time augmentation hurts medical image classification,” *arXiv preprint arXiv:2604.09697*, 2026.
- [58] F. Khattak, V. Subasri, A. Krishnan, *et al.*, “Mlhops: Machine learning for healthcare operations. published online may 3, 2023.”
- [59] R. Bartels, J. Dudink, S. Haitjema, D. Oberski, and A. van ‘t Veen, “A perspective on a quality management system for ai/ml-based clinical decision support in hospital care,” *Frontiers in Digital Health*, vol. 4, p. 942588, 2022.
- [60] D. Spadacini, “Clinical mlops: A framework for responsible deployment and observability of ai systems in cloud-native healthcare,” *Igmin Research*, vol. 4, no. 3, pp. 081–093, 2026.

- [61] L. Clifton, X. Tian, D. Palasuwan, P. Watanaboonyongcharoen, P. Rojnuckarin, and N. Anantrasirichai, “Mamba-based ensemble learning for white blood cell classification,” *arXiv preprint arXiv:2504.11438*, 2025.
- [62] S. Boosa and K. Allam, “End-to-end mlops pipeline on kubernetes for scalable healthcare applications,” *International Journal of Emerging Research in Engineering and Technology*, vol. 3, no. 1, pp. 74–85, 2022.
- [63] C. Anich, “Comparing custom and transfer-learning cnn models for chest x-ray classification: Evaluating performance and scalability with kubernetes orchestration.,” *TBD*, 2025.

Ekler

GitHub Deposu: WBC Analyzer — Multi-modal Agentic AI for White Blood Cell Classification

Model Dosyası: Google Drive

Bu ekler, çalışmada kullanılan kaynak kodu ve eğitilmiş derin öğrenme modelini içermektedir. GitHub deposu proje yapısını, veri işleme adımlarını ve model eğitimi sürecini; Drive bağlantısı ise nihai model dosyasını barındırmaktadır.