

Klinik Karar Destek Amaçlı Açıklanabilir Beyaz Kan Hücresi Sınıflandırması: Geliştirilen Derin Öğrenme Mimarisi ve Büyük Dil Modeli Entegrasyonu

Emirhan YILDIRIM

Bilişim Sistemleri Mühendisliği Bölümü


Sakarya Üniversitesi

emirhan.yildirim2@ogr.sakarya.edu.tr

Danışman: Dr. Öğr. Üyesi Fatma AKALIN

Giriş

Hematoloji laboratuvarlarında WBC sınıflandırması hâlâ manuel yürütülmekte; gözlemciler arası tutarsızlık ve cihaz/boyama farklılıkları tanı güvenilirliğini olumsuz etkilemektedir. Bu çalışmada özgün dikkat mekanizmaları ve LLM destekli Grad-CAM denetimi ile yüksek doğruluk ve alan kaymasına dayanıklı bir sistem geliştirilmiştir.




Şekil 1

Görsel, Raabin-WBC veri setinden 5 WBC tipinin mikroskop görüntülerini içermektedir. Bazofil en nadir sınıftır (%2.1) ve morfolojik ayırım en çok Lenfosit–Nötrofil çiftinde güçleşmektedir.

Veri Kümesi

Tahran Üniversitesi kaynaklı, etik onaylı Raabin-WBC veri seti kullanılmıştır. 5 WBC alt tipini kapsayan ~12.000 eğitim görüntüsü, 4.339 TestA ve 2.119 TestB görüntüsü içermektedir.




Şekil 2

Bu grafikte sınıf yüzde dağılımı verilmiştir. Nötrofil %61.2 ile baskındır ve bu dengesizlik standart cross-entropy ile yönetilememektedir

Ön İşleme ve Görüntü Normalizasyonu

Farklı cihazlardan gelen görüntülerdeki ışık, renk ve kontrast farklılıklarını gidermek amacıyla beş aşamalı Medical Enhanced Filter geliştirilmiştir. Reinhard renk normalizasyonu ile boyama ve donanım kaynaklı renk kayması giderilmektedir.




Şekil 4

Bu diyagramda ön işleme akışı gösterilmiştir. Her adım bir öncekinin bıraktığı gürültü veya bozulmayı hedef alır; eğer sıra değişirse performansın düşeceği görülmüştür.

Geliştirilen Model Mimarisi

DenseNet121 omurgası; parametre verimliliği ve yoğun bağlantı yapısıyla seçilmiştir. WBC Attention Block morfolojik bölgelere odaklanmakta, MedSwish aktivasyonu ise Dying ReLU sorununu gidererek ince kromatik doku gradyanlarını korumaktadır. İki aşamalı eğitimde önce backbone dondurulmuş, ardından tüm model ince ayar yapılmıştır..



Şekil 7

Bu görselde önerilen model mimarisi verilmiştir. Giriş görüntüsü MEF ön işlemeden geçtikten sonra DenseNet121 omurgası, WBCAttention Block ve MedSwish aktivasyonundan oluşan pipeline ile 5 WBC sınıfına sınıflandırılmaktadır.



Şekil 8

Bu görselde önerilen modelin DenseNet eğitim grafiği verilmiştir. 14. epoch'ta başlayan fine-tune ile doğruluk %98.53'e ulaşmış, kayıp düzgün biçimde düşmüştür.

Araştırma Bulguları ve Alan Adaptasyonu

Adaptasyon pipeline'ı üç adımdan oluşmaktadır: Binary Routing (+16.94 puan), Reinhard renk normalizasyonu (+12.56 puan) ve hafif TTA (+2.59 puan). Önerilen yöntem TestA'da %98.53 doğruluk ve 0.9853 Macro F1 ile karşılaştırılabilir çalışmaları geride bırakmakta; TestB'de +32.09 puanlık kazanımla güçlü genelleme yeteneği sergilemektedir.

Yöntem	TestA	TestB	Birleşik
Baseline V6 (adaptasyon yok)	97.46%	56.96%	84.17%
+ Binary routing (main_out)	97.46%	73.90%	89.73%
+ Reinhard renk normalizasyonu	97.99%	86.46%	94.21%
+ Hafif TTA — final konfigürasyon	98.53%	89.05%	95.42%


Tablo 1

Bu tabloda adaptasyon yöntemleri verilmiştir. Binary Routing +16.94 puanlık en büyük katkırı sağlar; üç teknik birleşince toplam kazanım +32.09 puana ulaşır.

Hücre Sınıfı	Kesinlik (Precision)	Duyarlılık (Recall)	F1-Skoru	Örnek Sayısı
Nötrofil	0.9962	0.9868	0.9915	2660
Lenfosit	0.9865	0.9884	0.9874	1034
Bazofil	1.0000	1.0000	1.0000	89
Monosit	0.9372	0.9573	0.9471	234
Eozinofil	0.9265	0.9783	0.9517	322
Ağırlıklı Ortalama	0.9856	0.9853	0.9854	4339

Web Servis ve Açıklanabilirlik Mimarisi

Geliştirilen Flask tabanlı REST API görüntüyü MEF ön işleme ve model çıkarımından geçirerek sınıf tahmini, güven skoru ve Grad-CAM ısı haritası üretmektedir. GPT-4o/Gemini destekli ajan kısayol öğrenme tespiti yapar; gerekirse Reinhard normalizasyon ile tahmin yenilenir.



Şekil 9

Bu diyagram sistem akış şemasını sunmaktadır. : Kısayol öğrenme tespit edilirse sistem Reinhard normalizasyon uygulayıp tahmini otomatik olarak yeniler.

Temel Katkı

Bu çalışma; sınıflandırma, alan adaptasyonu ve açıklanabilirlik denetimini tek klinik karar destek mimarisinde birleştirir. Model yalnızca "hangi hücre?" sorusunu değil, "model doğru bölgeye baktı mı?" sorusunu da cevaplar. Aşağıda çalışmanın öne çıkan sonuçları verilmiştir:

Öne Çıkan Sonuçlar

	Klinik Düzeyde Doğruluk Bağımsız test setinde, beş WBC alt tipinde ağırlıklı F1 skoru 0.985
	Yeniden Eğitim Gerekmez Yeniden eğitim yapılmadan %56.96'dan %89.05 doğruluğa sıçrama (Binary Routing + Reinhard + TTA)
	Gerçek Zamanlı Analiz Saf DenseNet121'e kıyasla 16 kat daha hızlı (232 ms → 14.2 ms)
	Nadir Hücre Tiplerini Kaçırmaz En nadir sınıfta (%2.1 Bazofil) %100 kesinlik ve %100 duyarlılık — sınıf dengesizliği WBC Focal Loss ile yönetildi
	Portatif, Hafif Model VGG16'nın yalnızca %6'sı boyutunda; klinik ortam için hafif ve dağıtılabilir